

学校编号 10394

图书分类号           

学    号 2015XXXX

密        级           



**福建师范大学**

**全日制学术学位研究生硕士学位论文**

**体域网动作模式稀疏表示识别技术研究**

**The Research of Sparse Representation**

**Classification for Action Pattern in Body**

**Sensor Networks**

**XXX**

学 科 专 业: 计算机应用技术

研 究 方 向: 传感器网络及其应用

指 导 教 师: XXX 博士 教授

申请学位级别: 工学硕士

论文提交日期: 2018 年 月 日

论文评阅人:                     

论文答辩日期: 2018 年 月 日

答辩委员会主席:                     

学位授予单位: 福建师范大学

学位授予日期: 2018 年 月 日

**2018 年 03 月**



## 中文摘要

近年来,新兴体域网技术在医疗康复监测、影视及游戏制作、专业动作分析等领域得到广泛关注和应用。当前相关研究大多采用稀疏表示分类算法解决体域网动作模式识别问题,但其中存在过完备字典规模过大、稀疏表示系数误差较大等问题,导致识别效率低下。本文尝试采用字典训练算法、(联合)稀疏表示分类算法、协作表示分类算法等解决上述问题。本文主要研究工作如下:

1. 传统稀疏表示分类算法中所采用过完备字典由大量高维动作数据拼合而成,导致字典规模过大,影响体域网动作模式分类算法性能。而且测试样本稀疏表示系数残差大多由简单平均叠加方法计算得到,难以逼近不同动作模式在空间中的分布状况。针对上述问题,本文提出了一种基于  $K$ -SVD 的最大似然稀疏表示体域网动作分类算法,该算法基于  $K$ -SVD 优化学习算法,将不同动作模式训练样本按其所属类别分组优化训练,避免各类样本数据训练时互相干扰,得到不同动作模式类别所属的子字典,然后将其拼合构成一个完整字典,准确稀疏表示测试样本,最后基于最大似然稀疏模型准确估计稀疏表示系数,判定测试样本所属类别;

2. 传统稀疏表示分类算法在处理多传感器动作数据过程中,通常将不同传感器所记录的人体动作数据看作是相互独立变量,无法充分发掘和有效利用多传感器动作信号之间存在的关联特性。本文采用联合稀疏表示分类算法处理多传感器动作数据,并改进  $D$ -KSVD 算法优化设计过完备字典,提出了一种基于  $D$ -KSVD 的联合稀疏表示动作识别算法。该算法基于改进  $D$ -KSVD 算法将不同类别动作模式分开训练获得各类别所属子字典,避免了不同类别动作数据相互干扰,并提升字典判别性能。随后采用联合稀疏表示分类算法估算测试样本基于过完备字典的稀疏表示系数,判定测试样本所属类别;

3. 传统稀疏表示分类算法用于识别多传感器动作数据时效率较低,为了减少体域网动作识别所需时间,本文基于最近邻思想重新构建规模更小的过完备字典,并结合协作表示提出了一种快速鲁棒协作表示动作分类算法,该算法首先基于最近邻原则寻找测试样本的近邻类别和近邻样本,重新构建训练样本集,减少训练样本集合大小,降低动作分类算法计算开销。然后构建鲁棒协作表示分类模型,通过扩展拉格朗日乘数算法求解测试样本的表示系数和残差,判定测试样本所属类别。

本文采用可穿戴动作识别数据库作为实验数据来源，通过设置参照实验，从动作识别率、算法时间复杂度等多个方面对所提算法进行评价。实验结果显示，本文所提几种算法识别性能明显优于传统机器学习算法以及稀疏表示分类算法，能够有效提升体域网动作模式分类性能，为后续相关研究提供新的思路和方法。

**关键词：**体域网，动作识别，稀疏表示分类，协作表示分类，最大似然估计，字典学习

## Abstract

In recent years, emerging body area network technologies have received extensive attention and applications in health monitoring, film and computer game production and professional motion analysis. Most of current related research attempts to solve the problem of action recognition in body sensor networks by using sparse representation classification algorithm. However, there are some problems in SRC algorithm, including the oversized scale of over-complete dictionary and the overmuch error of sparse representation coefficients. In this article, we attempt to save the problems above by using dictionary training algorithms, (joint) sparse representation classification algorithm, collaborative representation classification algorithm and so on. The main researching work in this article is following:

1. The over-complete dictionaries in traditional sparse representation classification algorithms consists of a large number of high-dimension action signals, which results in the oversized scale of dictionaries and influences action recognition algorithms' performance. The sparse representation coefficients residuals are obtained by simple average superposition and it is difficult to approach the distribution of different modes of actions in space. Designing for the issues above, a maximum likelihood sparse representation action classification algorithm based on K-SVD in body sensor networks is proposed. In this algorithm, all of action training samples are grouped according their classes to be trained, respectively. The mutual interference among different groups in the process of training can be avoided and sub-dictionaries for every class can be obtained. Then, these sub-dictionaries are used to construct an over-complete dictionary. And the dictionary is able to sparsely represent the testing samples precisely. The sparse representation coefficients are precisely approximated by maximum likelihood sparse model and the recognition results are determined by the coefficients.

2. In the process of multi-sensor action signals dealt by traditional sparse representation classification algorithms, the signals are usually regarded as mutually independent variables, which results in that the associated characteristics among action signals from different sensors can't be completely dig out and effectively utilized. In this article, joint sparse representation classification algorithm is adopted to process multi-

sensors action signals and D-KSVD algorithm has be improved to design the over-complete dictionary. Therefore, a joint sparse representation action recognition algorithm based on D-KSVD is proposed. Based on modified D-KSVD algorithm, the sub-dictionaries are optimized respectively, which is able to avoid the mutual interference among different kinds of action and promote the discriminative ability of dictionary. Then, the sparse representation coefficients of the testing sample can be obtained by joint construction method and the recognition results are determined by these sparse coefficients.

3. The traditional sparse representation classification algorithm is used to identify multi-sensor motion data with low efficiency. In order to reduce the time required for action recognition, the nearest neighbor idea is utilized to greatly reduce the dictionary size. The idea of collaborative representation is also merged in the proposed algorithm and a fast robust collaborative representation action recognition algorithm is proposed in this article. This proposed algorithm attempts to search the neighbor classes and samples of a test sample based on the nearest neighbor principle, which is helpful to decrease the calculation cost of the classification algorithm. Then robust collaborative representation classification model is built. The representation coefficients and residuals can be obtained by solving Augmented Lagrange Multiplier algorithm. The labels of test samples are determined by the representation residuals.

The wearable action recognition database is adopted to be the experimental data resource. The proposed algorithms are estimated by contrastive experiments from multi-reviews, including action recognition rate and time complexity. The experimental results show that the proposed algorithms overplay traditional machining learning algorithms and sparse representation classification algorithms and are able to improve the classification efficiency of human body action recognition based on BSN. This research provides new ideas and methods for the continuous related researching works.

**Keywords:** BSN, action recognition, sparse representation classification, collaborative representation classification, maximum likelihood estimation, dictionary learning

## 中文文摘

体域网是由穿戴于人体不同关节部位的多个加速度传感器构建而来，能够在一定条件下持续不断、准确地记录人体动作信号，为人体动作识别研究提供精确数据。近年来，基于体域网的人体动作模式识别技术取得了国内外研究人员的广泛关注，并成功应用于健康医疗监测、影视动画制作以及专业动作分析等领域。针对如何准确识别由加速度传感器所获取人体动作信号，早期研究大都采用包括近邻算法、支持向量机以及马尔科夫模型等在内的传统机器学习算法或者其改进算法。但是相关研究人员发现，在识别通过体域网所获取人体动作信号过程中，传统机器学习算法存在针对性较强、识别效率低下、算法复杂度较高等问题。

稀疏表示分类算法的提出解决了传统机器学习算法应用于基于体域网人体动作模式识别研究中存在的部分问题，该算法将所有训练样本构建一个过完备字典，准确稀疏表示测试样本，将体域网动作模式分类问题转化为测试样本稀疏表示系数求解问题，然后基于所求解的稀疏表示系数定义残差确定测试样本类别。虽然稀疏表示分类算法在人体动作识别问题研究中取得良好进展，但是研究发现基于稀疏表示的人类动作模式识别算法依旧存在一些问题。其一，稀疏表示分类算法将同一体域网中不同传感器节点所记录的人体动作信号看作相互独立，忽略了不同传感器节点所记录人体动作信号之间存在时空关联特性；其二，稀疏表示分类算法过分强调稀疏表示系数的系数特性，忽略了可能存在训练样本数量不足，从而导致稀疏表示系数残差较大，影响算法性能的问题；其三，过完备字典由大量高维训练样本数据所构成，一定程度上降低了人体动作识别算法运行效率，即增加动作识别耗时。

本文就体域网动作模式识别研究中所存在的上述关键技术问题，进行了详细的分析和深入的研究，主要研究内容如下：

第一部分为绪论。该部分首先简单说明了本文课题的研究背景与意义，随后详细阐述了当前国内外研究现状以及本文主要工作内容，最后简单介绍本文组织结构。

第二部分针对传统稀疏表示分类算法中过完备字典规模过大，且稀疏表示分类系数误差较大等问题，提出了一种基于  $K$ -SVD 的最大似然稀疏表示体域网动作分类算法。该部分详细阐述了基于大量高维人体动作信号的字典优化学习算法以及最大似然稀疏表示动作分类模型。并采用美国加州伯克利大学公开发布的包含多传感器数据的人体动作模式数据探讨字典学习算法参数设定。最后设定参照实验，与 NN、

KSVD 以及 SRC 等算法进行比较,验证所提算法识别人体动作模式的优越性能。实验结果显示,相对于几种参照算法而言,所提动作识别算法平均识别率达到 94%以上,具有明显优势。

第三部分在第二部分的基础上,进一步优化字典训练和稀疏表示系数重构算法,并提出了一种基于 D-KSVD 的联合稀疏表示动作分类算法。该部分详细阐述了基于多传感器人体动作数据优化设计字典学习方法,并将联合稀疏表示算法与改进 D-KSVD 算法相结合。为了验证该部分所提人体动作模式识别算法的优越性能,采用公开可穿戴动作识别数据库,在字典学习效率和识别效率两个方面对所提算法进行验证,并选择了 SRC 和 KSVD+SRC 等算法作为参照。实验结果显示,相较于 SRC 和 KSVD+SRC 而言,所提动作识别算法识别率较高,识别速度更快,具有明显优势。

第四部分针对传统稀疏表示分类算法时间复杂度较高的问题,结合最近邻思想和协作表示分类算法,提出了一种快速鲁棒协作表示人体动作分类算法。该部分阐述了鲁棒协作表示分类模型的构建过程,并详细说明了基于最近邻原则重新构建训练样本集方法,并采用可穿戴人体动作识别数据库对所提算法进行性能分析。实验结果证明,所提动作识别算法具有更快的识别速度和更高的识别率,具有明显优势。

第五部分为论文的总结与展望,该部分全面总结了本文的研究内容,并对后续研究问题和今后研究工作做出规划和展望。



# 目录

中文摘要 .....	I
ABSTRACT .....	III
中文文摘 .....	V
目录 .....	VII
绪论 .....	- 1 -
第一节 研究背景与意义 .....	- 1 -
第二节 国内外研究现状 .....	- 4 -
第三节 本文主要工作和创新点 .....	- 12 -
第四节 论文结构安排 .....	- 13 -
第一章 基于 K-SVD 的最大似然稀疏表示体域网动作分类算法 .....	- 15 -
第一节 引言 .....	- 15 -
第二节 基于 K-SVD 的最大似然稀疏表示体域网动作分类算法 .....	- 15 -
第三节 实验结果和分析 .....	- 18 -
第四节 本章小结 .....	- 22 -
第二章 基于 D-KSVD 的联合稀疏表示动作识别算法 .....	- 23 -
第一节 引言 .....	- 23 -
第二节 基于 D-KSVD 的联合稀疏表示动作分类算法 .....	- 23 -
第三节 实验结果和分析 .....	- 27 -
第四节 本章讨论 .....	- 32 -
第五节 本章小结 .....	- 33 -
第三章 一种快速鲁棒协作表示动作分类算法 .....	- 35 -
第一节 引言 .....	- 35 -
第二节 快速鲁棒协作表示动作分类算法 .....	- 35 -
第三节 实验结果与分析 .....	- 39 -
第四节 本章小结 .....	- 43 -
第四章 结论 .....	- 45 -

第一节 论文工作总结 .....	- 45 -
第二节 未来工作展望 .....	- 46 -
参考文献 .....	- 47 -
攻读学位期间承担的科研任务与主要成果 .....	- 55 -
致 谢 .....	- 57 -

## 绪论

### 第一节 研究背景与意义

20 世纪中后期，心理学家通过实验发现采用摄像机记录固定在人体关节高亮反射点的关节点行动轨迹，能够有效分辨人体的不同动作模式，其中包括步行、慢跑、跳跃等。此后，人体动作识别开始进入相关研究人员的视野<sup>[1]</sup>，并逐步成为一个新兴研究领域，取得众多研究人员广泛关注。初始阶段，大多数研究基于高速摄像头获取的人体动作视频序列实现<sup>[2-4]</sup>，其基本思路是：首先通过高速摄像头获取人体动作视频序列，然后提取视频序列中人体轮廓数据，最后采用合适算法分析采集所得数据判定人体动作模式类别，该过程基本步骤如图 1 所示。虽然基于视频序列人体动作识别有所突破并取得良好进展，但是科研人员逐渐发现，通过高速摄像头获取人体日常动作视频序列存在较多缺陷。例如，高速摄像头记录人体动作视频序列的过程中容易受到光线、障碍物阻挡等因素影响，导致视频序列缺损、不清晰；高速摄像头存在采集范围有限、视角固定、成本较高等缺点，并且基于视频序列无法提取高精度人体动作信号数据；此外，受试者被要求持续不断暴露在摄像头之中，其个人隐私无法得到有效保护<sup>[5]</sup>。




图 1 基于视频序列的动作识别算法流程图

Fig. 1 The diagram of video-based activity recognition algorithms

近年来，体域网<sup>[6-9]</sup>（Body Sensor Networks, BSN）技术的兴起与发展取得了广泛关注和应用。该技术实现思路在于将多个传感器节点佩戴于受试者肩、肘、腕、腰、膝、踝等关节部位，构建小型局域网，用以捕获人体动作信号，为判别人体运动功能变化提供可靠数据，体域网完整框架如图 2 所示。得益于微机电系统（Micro Electro-Mechanical System, MEMS）技术的快速发展，一个传感器节点可以内嵌数个

陀螺仪或加速度计，能够持续不断、精确记录人体动作数据。相对于采用高速摄像头采集人体动作信号，传感器节点具有灵敏度高、体积微小、价格低廉、能耗更低等优点。除此之外，相对于高速摄像头采集人体动作信号，传感器节点仅仅只能够采集人体动作数据，不具有侵犯个人隐私的功能特性。传感器节点在一定条件下能够持续不断地工作，足以保证捕获所得动作数据完整性较高。




图 2 体域网框架结构图

Fig. 2 The diagram of BSN framework structure

当前，基于多个传感器节点获取动作信号<sup>[10-13]</sup>已经成为体域网技术典型应用场景，并成功运用于医疗康复监测、影视和游戏制作以及专业动作分析等领域<sup>[14-15]</sup>。

#### (1) 医疗康复监测

随着科学技术和社会经济的高速发展以及生活水平的日益增长，人们对于提高生活质量，尤其是身体健康方面，投入了更多关注。联合国人口基金会数据显示，全球人口总数已于 2016 年突破 72 亿，并且处于持续增长状态。人口急剧膨胀带来了极大的医疗压力，尤其是医护人员短缺，致使慢性病（包括心血管疾病、糖尿病、高血压等）患者无法得到及时有效的护理。据世界卫生组织数据显示，2015 年全球死于心血管疾病总人数超过 1770 万，占死亡总数 31%。如何有效监测慢性病患者的各项生理指标和行为动作，减少病人前往医院就诊次数，提高医护人员工作效率以及医疗监护舒适度、便捷性，已经成为当今社会的焦点问题。

## (2) 影视和游戏制作

在过去几年时间里，人体动作识别技术已经成功运用于影视作品制作过程中。首先在演员身体之上佩戴多个传感器，在特定环境（环境干扰因素忽略不计）下捕获演员完整动作数据，再利用算法分析，得到人体动作真实数据模型。电影后期制作人员通过计算机模拟真实场景，加载人体动作数据，让虚拟角色的动作极为逼近真实动作。此外，在确保安全的情况下获取一些危险动作数据，然后通过计算机建模构造真实动作，在确保影视作品的观赏性的同时，能够保证演员人身安全。在游戏制作过程中，可以基于真实动作数据构建虚拟游戏角色，增强游戏效果，为玩家提供更好的游戏体验。

## (3) 专业动作分析（竞技体育）

人体动作识别技术近年来同样运用于专业动作分析，尤其是职业运动员动作监测。众所周知，竞技体育对于运动员动作标准要求极为严苛。运动员在平时训练过程中，只能依靠教练观察或是观看录像带找出自身动作的不足之处，较为容易受到人为主观影响做出不恰当的判断，从而可能导致训练进展缓慢。采用体域网技术可以在运动员的身体之上佩戴多个传感器节点，持续不断捕获运动员动作数据，利用算法评估其动作是否符合要求，同时也可以对运动员的运动量进行监控和警示，提防运动过度导致受伤或身体受损。

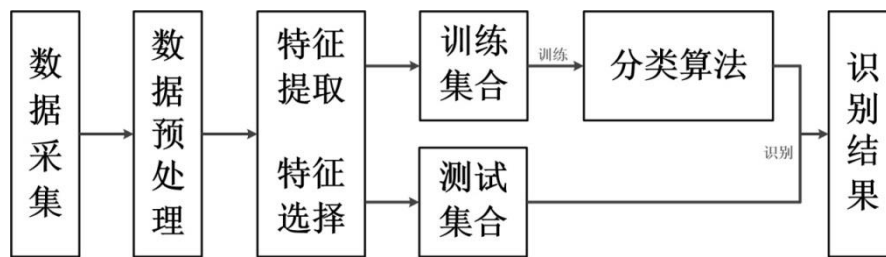


图 3 基于加速度传感器人体动作模式识别算法流程

Fig. 3 The process of acceleration-sensor-based human activity pattern recognition algorithms

在基于体域网的人体动作识别技术得到广泛关注和运用的同时，如何优化设计识别算法、提高人体动作识别率成为相关研究领域一个热点问题。早期研究主要采用传统机器学习算法识别不同人体动作模式，其基本思路是：采用单个或多个加速度传感器节点记录人体动作数据，然后对数据进行信号消噪、特征提取和选择等预处理，最后选择或设计合适的分类算法判别测试样本所属类别，该过程具体示意图

如图 3 所示。2009 年, Wright 等人<sup>[16]</sup>首度提出稀疏表示分类算法, 并成功应用于人脸识别, 为模式识别研究提供了新方法。该算法基本思路是: 将所有训练样本级联构成一个过完备字典, 随后基于该字典求解测试样本对应稀疏表示系数, 最后计算稀疏表示系数以及残差, 并判定测试样本所属类别。随后, 稀疏表示分类算法被引入人体动作识别研究<sup>[17-18]</sup>中, 并取得良好进展。但是随着相关研究的深入, 研究人员发现对于人体动作模式, 无论机器学习算法, 还是稀疏表示分类算法, 均存在一些缺陷。传统机器学习算法无法直接处理高维复杂的人体动作数据, 在识别过程中, 需要经过一系列预处理操作, 无疑增加了动作识别算法时间复杂度。与此同时, 源于机器学习的人体动作模式识别算法针对性较强(识别动作种类较少)、识别效果差强人意。而早期运用稀疏表示分类算法求解人体动作模式识别问题时, 由于过分强调稀疏表示系数的稀疏性, 且大多相关研究采用简单平均叠加方法计算测试样本稀疏表示系数, 难以准确描述不同动作模式在空间的分布状况, 也可能影响其分类性能。此外, 传统稀疏表示分类算法中所采用过完备字典是由大量高维动作样本拼合而成, 规模过大, 一定程度上增加识别算法时间复杂度; 过完备字典规模较大带来另一个负面影响是其中可能含有的大量冗余信息会削弱识别算法识别性能。

实际应用场景往往要求动作识别算法具有较高识别性能以及短时间识别动作类型。以医疗监测康复为例, 监测中心为了保证实时掌握病人病情, 需要监测设备能够快速准确地识别人体动作。如果识别结果出错或是识别速度较慢, 则有可能导致病人无法得到及时有效处理, 耽误病情。由此可见, 提升基于体域网的人体动作识别算法性能、降低时间复杂度, 对于体域网技术应用于实际场景具有重要现实意义。

## 第二节 国内外研究现状

### 1. 动作识别数据集(库)及其预处理

在人体动作识别研究过程中, 动作数据集(库)是一个重要必备条件。但较为完善而广受认可的人体动作数据集(库)在研究早期处于一片空白状态。因此, 相关研究人员不得不自行设计信号采集设备用以捕获人体动作数据。其中, 如何选择传感器、传感器佩戴位置、传感器数量等都是研究人员重点考虑因素。Zhu 等人<sup>[19]</sup>采用两个可穿戴惯性传感器, 分别佩戴于测试者的腰部和脚踝处, 成功捕获了包括行走、下楼、上楼和跑步等人体动作信号; Cohn 等人<sup>[11]</sup>采用一个超低功率传感器, 通过测量人体任何一个位置的电压, 使用静态电场快速感应身体运动, 并顺利采集

了包括走、慢跑等四种动作数据；Ling 等人<sup>[20]</sup>采用了 5 个小型双轴加速度计，同时佩戴于人体四肢以及臀部，用于获取人体动作数据，包括行走、跑步等共计二十种人体动作数据。而近年随着智能手机等移动设备的普及，部分研究开始采用智能手机作为记录人体动作数据的主要工具<sup>[21-24]</sup>。Riboni 等人<sup>[21]</sup>采用配置了加速度计传感器的手机和手表作为捕获人体动作数据的采集工具，成功获取了慢跑、上楼、下楼等十余种人体动作数据；Anguita 等人<sup>[22]</sup>将一台 Samsung Galaxy S2 缚于受测者腰部，顺利捕获了包括走、上楼、下楼等六种人体动作数据；Martin 等人<sup>[23]</sup>采用一部 Google Nexus S 智能手机持续记录受试者一天的动作数据，并成功从中提取了走、坐、慢跑、快跑等多种动作模式；Siirtola 等人<sup>[24]</sup>同时采用两部智能手机（Nokia N8 和 Samsung Galaxy Mini）记录了包括走、站立、坐、跑等七种人体动作数据。

由上述内容可以看出，不同硬件设备记录所得动作数据具有较大差异性，各数据不具有统一标准，基于不同来源动作数据所设计的识别算法针对性较强，无法为后期研究提供更多参考价值。因此，构建较为完善而广受认可的人体动作数据集（库）成为该研究领域当务之急。相关研究成果中，美国南加州大学发布的人体行为数据集<sup>[25]</sup> (University of Southern California Human Activity Dataset, USC-HAD) 和加州伯克利大学公开发布的可穿戴动作识别数据库<sup>[18]</sup> (Wearable Activity Recognition Database, WARD) 是目前体域网动作模式识别研究中采用最为广泛的数据集（库）。USC-HAD 数据集包含共计 14 名测试者（7 名男性，7 名女性，年龄处于 21~49 岁之间）12 种日常动作信号数据，每名测试者佩戴一个高性能惯性传感器佩戴于腰部（髋关节处），节点采集频率为 100Hz。WARD 数据库包含共计 20 名测试者（13 名男性，7 名女性，年龄介于 19~70 岁之间）13 种日常动作的信号数据。每名受试者佩戴 5 个传感器（内嵌一个 3 轴加速度传感器和一个 2 轴陀螺仪），分别置于测试者的双手手腕，双脚脚踝和腰部，节点采集频率为 20Hz。

考虑到人为因素影响，通过传感器节点捕获人体动作信号具有不确定性、随机性等特点。因此，不同测试个体所得原始动作数据维度无法保持一致。为了方便处理，相关研究采用不需要任何前置条件的滑动窗口技术对原始动作数据进行截取，以确保所有动作数据具有统一维度。至于滑动窗口长度，则需要根据传感器节点的采集频率进行确定。一般而言，为了确保截取后的一个动作样本包含完整动作，滑动窗口长度会选取 5s 左右时间。此外，通过传感器节点捕获所得人体动作信号维度普遍较高，含有较多冗余信息，可能导致识别算法时间复杂度大幅提升并且识别性

能不佳。因此，对于原始动作数据，提取和选择具有较好区分度的数据特征是保证人体动作识别算法具有良好性能的有效手段。特征提取旨在将高维数据样本转化为更具有更好区分度的低维数据样本，其主要作用在于高维数据的分类和可视化。最常用特征提取方法包括主成分分析(Principle Component Analysis, PCA)、线性判别分析(Linear Discriminative Analysis, LDA) 和独立分量分析 (Independent Component Analysis, ICA)等算法。PCA 算法旨在转化原始特征为相互独立新特征的线性算法，这些新特征被称为主成分。LDA 算法也是通过线性变换提取特征，与 PCA 算法的不同点在于，该算法将原始特征点投影到一个新的低维空间，最大化类间可分性，同时最小化类内变异。ICA 算法是另一种非高斯数据常用特征提取技术，该算法致力于在大量数据中寻找独立组件，通过搜索原始数据特征的投影，使得不同投影数据的概率分布在统计上相互独立。特征选择是指从原始特征集合或是经提取后的特征集合中搜索、选择适当特征子集的过程。特征选择一般分为过滤方法<sup>[26]</sup>、包装方法<sup>[27]</sup>、混合方法<sup>[28]</sup>等几类。

## 2. 机器学习算法与动作识别

目前，运用于日常动作识别相关研究的机器学习算法包括  $K$  均值 ( $K$ -Means)、支持向量机 (Support Vector Machine, SVM)、决策树 (Decision Tree, DT)、 $K$  近邻 ( $K$ -Nearest Neighbor, KNN)、马尔科夫模型 (Markov Model, MM)等常用算法，相关研究如表 1 所示。

表 1 体域网动作识别相关研究列表

Tab.1 The list of activity-recognition-related researches based on BSN

算法	参考文献
$K$ 均值	[30], [31]
$K$ 近邻	[1], [32], [33]
决策树	[20], [34], [35]
马尔科夫模型	[36], [37], [38], [39]
支持向量机	[15], [39], [40], [41], [42], [43], [44]
其他算法	[45], [46], [47], [48]



机器学习算法主要分为两大类：有监督学习算法和无监督学习算法<sup>[29]</sup>。其中有监督学习算法包括：KNN、DT、ANN、SVM 等，此类算法需要人为对所有人体动作训练样本进行标记；无监督学习算法包括：K-Means、MM 等，该类算法允许自动推算样本标签，不需要人为标记所有人体动作样本。下文将会介绍上述各种算法在体域网人体动作识别算法研究中具体应用。

#### (1) K 均值算法

K-Means 算法是一种无监督分类（聚类）技术，该算法可以将  $n$  个对象分为  $K$  类。Ong 等人<sup>[30]</sup>使用一个 RGB-Depth 传感器采集了包括走、站、坐等十几种人体动作数据，并采用 K-Means 算法进行分类，平均识别率约为 83.8%。Cottone 等人<sup>[31]</sup>采用 K-Means 算法对慢跑、拍手、扔东西等 18 种人体动作进行识别，平均识别率达到 86.5%。该算法没有定义样本数据密度，无法判定样本分类的不确定性，当样本数据存在重叠簇时，K-均值聚类效果可能表现较差。因此可以看到上述实验中人体动作平均识别率均未超过 90%。

#### (2) K-近邻算法

KNN 算法采用欧式距离定义数据样本之间的相似度，距离越小相似度越高，以训练样本为基判定测试样本所属类别。Chamroukhi 等人<sup>[33]</sup>利用 MTx-Xbus 惯性跟踪器采集了下楼、上楼、走、坐、躺等 12 种人体动作数据，并采用 KNN 算法对动作数据进行识别，平均识别率可达到 90%以上。KNN 是一种有监督分类算法，不需要学习过程，算法复杂度较低，识别性能一般，但是稳定性不足。

#### (3) 决策树

DT 算法应用于人体动作识别时的主要思路是利用训练样本构建一个分层模型（树），所有模型属性被映射到决策节点，每个分支代表一种可能，从根节点出发到所有树叶节点的每一条路径都是一种分类规则。该算法属于有监督分类算法，最常用的 DT 算法有 C4.5、ID3 等。Jatobá 等人<sup>[35]</sup>采用 C4.5 决策树识别走、站立、骑单车、躺等 20 种动作模式，平均识别率达到 84.25%；Ling 等人<sup>[20]</sup>采用三轴加速度传感器记录人体动作数据，并采用 ID3 决策树对走、慢跑、爬楼梯等多种人体动作模式进行识别，而平均识别率仅为 79%。

#### (4) 马尔科夫链和隐式马尔科夫模型

马尔科夫链能够展示一个包括有限个离散状态的随机过程，每一个状态依赖于其前一个状态。马尔科夫模型是基于马尔科夫链对连续型数据进行建模所构建的一

种分类模型。Vihn 等人<sup>[36]</sup>使用 2 个惯性传感器和一台掌上电脑 (Personal Digital Assistant, PDA)同时记录人体动作数据,采用隐式马尔科夫模型 (Hidden Markov Model, HMM)对走、上楼、下楼、跑等多种人体动作模式进行分类,各类别动作模式识别率处于 87%至 92%之间。Trabelsi 等人<sup>[37]</sup>提出 Semi-CRF(Semi-Markov Conditional Random Fields)模型,虽然该模型适用范围较广,但是需要大量训练数据,而且其参数的确定需经过多次迭代计算,且识别率最高仅能达到 89%。Lester 等人<sup>[38]</sup>基于隐式马尔科夫模型提出一种新 MHMMR (Segmentation with Multiple Hidden Markov Model Regression)模型,对包括站、走、上楼等 12 种动作模式进行分类,平均识别率达到 91.4%左右。He 等人<sup>[39]</sup>基于多传感器体域网所记录多达十余种动作数据,比较了包括朴素贝叶斯 (Naïve Bayes, NB),高斯混合模型 (Gauss Mixed Model, GMM), K-近邻, 人工神经网络 (Artificial Neural Networks, ANN)在内的多种机器学习算法对于人体动作模式的识别效果,最终得出结论,基于 HMM 的动作识别算法性能最佳。但是与 GMM 相比, HMM 模型无法保证收敛到全局最小值。

#### (5) 支持向量机

SVM 是一种有监督线性分类技术,但是可以通过使用核方法将其扩展为非线性分类器。该算法最大限度地减少了经验风险,同时最大限度地提高了分离超平面和数据之间的界限。He 等人<sup>[41]</sup>提取动作数据的六维无权重特征,采用 SVM 对人体动作模式进行分类,识别率高达 97.2%。Doukas 等人<sup>[44]</sup>结合支持向量机和多重特征空间,有效加强了基于少量训练样本的标准贝叶斯分类器人体动作模式识别性能。SVM 是一种二元分类器,人体动作模式分类问题包含多种类别,需要使用成对分类的策略,导致分类算法复杂度提升,极为耗时,当数据量偏大时尤为明显。

#### (6) 其他算法

除了上述几种常见的机器学习分类算法之外,研究人员还尝试使用其他算法解决基于体域网的人体动作模式识别问题。例如,Bedogni 等人<sup>[47]</sup>比较了多种算法(包括随机森林、支持向量机和朴素贝叶斯算法等)识别不同类别人体行为的效果,该项研究结果显示随机森林对于人体动作模式识别率高于其他算法。Andrea 等人<sup>[48]</sup>采用躯干磨损惯性传感器和 BP 传感器采集了十二名受试者的人体动作数据,采用模糊逻辑算法进行识别,识别率可达 90%。Altun 等人<sup>[49]</sup>尝试采用人工神经网络、贝叶斯决策 (Bayesian Decision Making, BDM)、最小二乘法 (Least Squares Method, LSM)、动态时间规整 (Dynamic Time Warping, DTW)等算法识别人体动作模式。

由上述内容可以看出，机器学习算法在体域网人体动作模式识别研究过程中发挥了关键作用，相关研究也取得良好进展和识别效果。但是，近期研究发现基于机器学习算法的研究成果已经无法满足实际应用需求，其主要原因在于针对体域网动作模式识别问题，机器学习算法的表现尚存在以下不足：

(1) 时间复杂度偏高。通过传感器采集所得人体动作数据具有高维度、冗余信息较多等特点，机器学习算法无法直接处理原始数据，必须事先进行数据预处理，其中包括数据消噪、特征提取和选择等多个步骤，增加了人体动作模式识别过程繁琐程度，增加了算法复杂度；

(2) 识别效果不佳。综合众多研究结果可以发现，大部分基于机器学习算法（或模型）的人体动作模式识别率处于 75%至 90%范围之内，难以满足实际应用要求；

(3) 针对性较强，不具有普适性。出于技术条件限制，早期研究中所采用的人体动作模式类别局限在 4~6 种，对于上楼和下楼，向左走和向右走等相似度较高的人体动作模式，辨别能力不足。

### 3. 稀疏表示人体动作分类算法

近年来，一种新兴稀疏表示分类 (Sparse Representation Classification, SRC)算法在体域网动作模式识别研究中受到广泛关注<sup>[16]</sup>。该算法基本思路是：将所有训练样本拼合在一起构建完备字典，准确稀疏表示测试样本（即，与测试样本同类为非零系数，非同类为零系数），将体域网动作模式分类问题转化为测试样本稀疏表示系数求解问题，然后基于所得稀疏表示系数计算测试样本对应的稀疏表示残差确定测试样本所属类别。关于人体动作识别研究，Yang 等人<sup>[17]</sup>提出一种基于单个传感节点加速度数据的人体动作模式稀疏表示分类算法，对 9 种不同动作模式分类，平均识别率可达 95.3%。Zhang 等人<sup>[18]</sup>基于多传感节点加速度数据，提出一种基于稀疏表示分类算法的分布式体域网动作模式识别模型，对 13 种不同动作模式分类，平均识别率可达 93.5%。肖玲等人<sup>[50]</sup>基于多传感器加速度数据提出一种基于稀疏表示动作分类算法，但该算法基于 13 种不同类别动作模式的平均识别率仅有 89%。虽然稀疏表示分类算法在人体动作识别问题研究中取得良好进展，但是研究发现基于稀疏表示的人体动作模式识别算法依旧存在以下问题。

首先，稀疏表示分类算法将同一体域网中不同传感器节点所记录人体动作信号看作相互独立变量，忽略了不同传感器节点所记录人体动作信号之间存在时空关联

特性, 但该特性若能得到有效挖掘和利用, 可以有效提升多传感器体域网动作模式识别算法性能。为此, Yuan 等人<sup>[51]</sup>提出了一种多任务联合稀疏表示分类算法(Joint Sparse Representation Classification, JSRC), 该算法基本思想是: 将多观测样本(多传感器体域网中不同加速度传感器所记录的人体动作数据)看作是一个整体, 使得所有观测视角(即所有加速度传感器)共享同一个稀疏模型, 然后采用联合稀疏表示算法重构测试样本, 并计算重构残差, 判定测试样本所属类别。Xiao 等人<sup>[52]</sup>基于多传感器加速度数据, 提出一种基于分布式随机投影的联合稀疏表示分类算法, 对十三种不同动作模式分类, 因为其实验数据中包含动作模式种类较多, 且相似度较高, 总体平均识别率仅达到 88.77%。

其次, 稀疏表示分类算法的一个重要思想是基于全部训练样本级联构成过完备字典, 通过求解范式优化问题获取测试样本稀疏表示系数, 突出强调稀疏表示系数的稀疏特性, 忽略了可能存在训练样本数量不足, 导致稀疏表示系数残差偏大, 影响分类算法性能的问题<sup>[53-54]</sup>。近年相关研究大多采用简单平均叠加方法计算测试样本稀疏表示余差, 难以准确逼近不同动作模式在空间的分布状况, 也可能影响其分类性能。Yang 等人<sup>[55-56]</sup>提出了最大似然估计 (Maximum Likelihood Estimation, MLE) 模型, 该模型能够准确逼近稀疏表示残差, 其基本思想就是将余项的求解由  $l_1$  或  $l_2$  范式优化转化为一个似然估计算子, 利用最大似然函数, 更加准确估算稀疏表示残差值。目前, 就相对于由  $l_1$  或  $l_2$  范式优化而言, 基于最大似然估计模型构建稀疏表示体域网动作模式分类算法, 使体域网动作模式训练样本所得最大似然估计函数更具有通用性, 能够获得更精确的测试样本表示残差, 通过减少稀疏表示系数误差而降低识别算法判别动作样本所属种类的错误率, 从而有效提升体域网人体动作模式分类性能。而且采用最大似然估计模型能够有效削弱稀疏表示算法对于表示系数稀疏性的依赖。目前基于最大似然估计模型求解人体动作识别问题相关研究鲜有报告。

最后, 稀疏表示分类算法所采用的过完备字典由大量高维训练样本数据所构建, 虽然能够最大限度保证得到全局最优解, 但是规模较大的过完备字典降低了人体动作识别算法运行效率, 即增加识别算法时间复杂度。另一方面, 过完备字典规模过大, 可能包含大量冗余信息, 导致削弱人体动作识别算法性能。因此, 寻找一个优化过完备字典, 进一步提炼训练样本所含判别信息, 是提升稀疏表示分类算法性能关键所在。基于字典优化算法构建稀疏表示分类模型的思路近期被许多研究人员所关注。一种基于 K-SVD 学习算法<sup>[57]</sup>优化设计过完备字典近年来在人脸稀疏表示识

别、动态手势稀疏表示识别研究中得到广泛应用,其基本思路是基于优化学习算法,从大量训练样本数据中提炼区分度较高的判别信息,获取优化过完备字典,既有效减少样本数据量,又可准确稀疏表示测试样本,确保判别信息不丢失。此外,D-KSVD (Discriminative K-SVD)算法<sup>[58]</sup>在 K-SVD 算法的基础上做出改进,其基本思路是:首先采用 K-SVD 算法初始化过完备字典,再引入标签信息和罚因子并迭代更新字典,直到获取判别性过完备字典和相应的分类器。Serra 等人<sup>[59]</sup>结合 K-SVD 算法和贝叶斯算法,提出 Bayesian K-SVD 算法,该算法利用贝叶斯算法只需要先验知识的特点,弥补了 K-SVD 算法中需要对噪音精确估计的缺陷,但是该算法在执行训练过程之前,需要通过大量计算获取必要的先验知识,大幅增加了算法复杂度。Jiang 等人<sup>[60]</sup>提出了一种 LC-KSVD 算法,将判别稀疏编码误差和分类误差融入到 K-SVD 字典优化学习过程中,最终识别效果相对于 K-SVD 算法有所提升,但该算法在字典训练过程中添加多项误差以用于修正字典精确度,提升字典判别性能以增加识别算法时间复杂度为代价。

采用字典优化设计算法旨在提取训练样本中含有的判别信息,削减过完备字典规模,从而降低算法复杂度。不过,获得一个普适性强、体量小、判别性高的过完备字典依赖于大量训练动作样本,因此,字典学习本身就是一个复杂的过程。为此,近年相关研究提出一种快速稀疏表示分类算法<sup>[61]</sup>(Fast Sparse Representation Classification, FSRC),其基本思路是基于最近邻 (Nearest Neighbor, NN) 思想,寻找一个与测试样本相似、规模较小的训练样本集,降低算法复杂度并提升算法识别性能。FSRC 算法为每一个训练样本定制专属训练样本集合,避免了字典优化设计过程,有效降低算法复杂度。此外,吴建宁等人<sup>[62]</sup>提出一种基于随机投影的快速稀疏表示动作分类算法 (Fast Sparse Representation Classification Based on Random Projection, FSRC\_RP),该算法采用随机投影算法对原始人体动作信号压缩,并基于简化 KNN 近邻算法为测试样本重新构建训练样本集,有效降低算法复杂度,而且对 9 种不同人体动作模式的平均识别率超过 92%。以上研究成果为我们优化设体域网动作模式识别算法提供了可借鉴思路。

### 第三节 本文主要工作和创新点

为有效提升基于体域网的人体动作模式识别算法性能，本文从字典优化学习和稀疏系数重构算法优化等方面展开研究，尝试解决传统稀疏表示分类算法中字典规模过大、稀疏表示系数误差较大等问题。本文主要工作如下所述。

(1) 近期相关研究大多采用简单平均叠加方法计算测试样本稀疏表示余差，难以准确逼近不同动作模式在空间中的分布状况。相关研究提出了最大似然估计模型，将稀疏表示残差的求解由  $l_1$  或  $l_2$  范式优化转化为一个似然估计算子，利用最大似然函数更加准确估算稀疏表示残差值。本文尝试结合字典学习算法和最大似然估计模型，提出一种基于 K-SVD 的最大似然稀疏表示体域网动作分类算法。该方法基于 K-SVD 优化学习算法，将不同动作模式训练样本按其所属类别分组优化训练，避免各类样本数据训练时相互干扰，得到不同动作模式类别所属的子字典，然后将所有子字典级联构成完备字典，准确稀疏表示测试样本，最后基于最大似然稀疏模型准确估计稀疏表示系数残差，判定测试样本所属类别

(2) 传统字典优化设计算法将全部训练样本看作一个整体，训练过程中，不同类别动作模式相互干扰，一定程度降低字典判别性。本文第三部分基于 D-KSVD 算法优化设计一种新的字典学习算法，将不同类别人体动作模式分开进行训练，避免不同类别动作数据相互干扰，提升字典判别性能，并结合联合稀疏表示分类算法提出一种基于多传感器体域网的人体动作模式分类新算法。该算法基于改进的 D-KSVD 算法优化字典，有机融合体域网中多传感器节点人体动作数据，并通过联合稀疏表示算法发掘更多人体动作信号之间的关联特性，精确获取测试样本的稀疏表示系数，判定测试样本所属类别。

(3) 本文第四部分提出一种快速鲁棒协作表示动作分类算法。该算法基于最近邻原则寻找测试样本的近邻类别和近邻样本，重新构建该测试样本的专属训练样本集，减小训练样本集规模，削减表示基信息冗余度，同时降低动作分类算法时间复杂度；然后构建快速鲁棒协作表示分类模型，通过扩展拉格朗日乘数算法求解测试样本的表示系数和表示残差，判定测试样本所属类别。

## 第四节 论文结构安排

本文内容共分为五个部分，具体组织结构如下所述：

第一部分为绪论。该部分首先简单说明了本文的研究背景与意义，随后详细阐述了本课题相关的当前国内外研究现状以及本研究的主要工作内容，最后简单介绍了本文的组织结构。

第二部分为有效提高体域网动作分类性能，该部分提出了一种基于 K-SVD 的最大似然稀疏表示体域网动作分类算法。首先详细阐述了基于大量高维人体动作信号的字典优化学习算法以及最大似然稀疏表示动作分类模型。随后采用美国加州伯克利大学公开发布的包含多传感器数据的人体动作模式数据 WARD (Wearable Activity Recognition Database) 探讨字典学习算法参数设定。最后通过与 NN、KSVD 以及 SRC 等算法进行比较，验证所提算法识别人体动作模式的优越性能。

第三部分提出了一种基于 D-KSVD 的联合稀疏表示人体动作分类算法。首先说明了基于多传感器人体动作数据优化设计字典学习方法，随后介绍了联合稀疏表示算法与改进 D-KSVD 算法的结合。最后采用 WARD 数据库，在字典学习效率和人体动作识别效率两个方面对所提算法进行验证，并选择了 SRC 和 KSVD+SRC 等算法作为参照。

第四部分提出了一种快速鲁棒协作表示人体动作分类算法。首先详细介绍了鲁棒协作表示分类模型的构建过程，随后介绍了基于最近邻原则重新构建训练样本集的方法，最后采用可穿戴动作识别数据库对该算法进行性能分析。

第五部分为论文的总结与展望，该部分全面总结了本文的研究工作，并对后续研究问题和今后研究工作做出规划和展望。





# 第一章 基于 K-SVD 的最大似然稀疏表示体域网动作分类算法

## 第一节 引言

传统稀疏表示人体动作分类算法将所有训练样本级联作为过完备字典，导致字典规模过大，影响识别性能。更重要的是，近年相关研究大多采用简单平均叠加方法计算测试样本系数表示余差，难以准确逼近不同动作模式在空间的分布状况，也可能影响人体动作识别算法性能。本章尝试结合 K-SVD 字典学习算法和最大似然估计模型，提出了一种体域网动作模式分类新算法，其基本思想：首先基于 K-SVD 优化学习算法，将不同动作模式训练样本按其所属类别分组优化训练，避免各类样本数据训练时相互干扰，得到不同动作模式类别所属的子字典，然后将其拼合构成一个完整字典，准确稀疏表示测试样本，最后基于最大似然稀疏模型准确估算稀疏表示系数残差，有效提高动作模式分类性能。本研究采用包含多传感数据的人体动作数据库 WARD 验证本章所提算法有效性。与传统稀疏表示分类算法相比较，本章所提算法能够准确估计测试样本稀疏表示残差，显著提高动作模式识别率。

## 第二节 基于 K-SVD 的最大似然稀疏表示体域网动作分类算法

本章所提算法旨在将 K-SVD 优化学习算法和最大似然估计相结合，优化设计过完备字典，基于较少训练样本数据准确稀疏表示测试动作样本，然后构建测试样本稀疏表示残差最大似然估计模型，判断其类别。算法框架如图 1-1 所示，由优化设计过完备字典的训练阶段和基于最大似然稀疏表示的动作识别阶段组成。训练阶段主要是基于 K-SVD 分别每个动作类别优化学习获得子字典，然后将所有优化子字典整合一个完整字典，有效减少冗余样本数据，准确稀疏表示测试样本。识别阶段主要是采用最大似然估计模型估算稀疏表示余差分布密度函数，然后基于余差分布密度函数求解测试样本稀疏表示残差，判别测试样本所属类别。

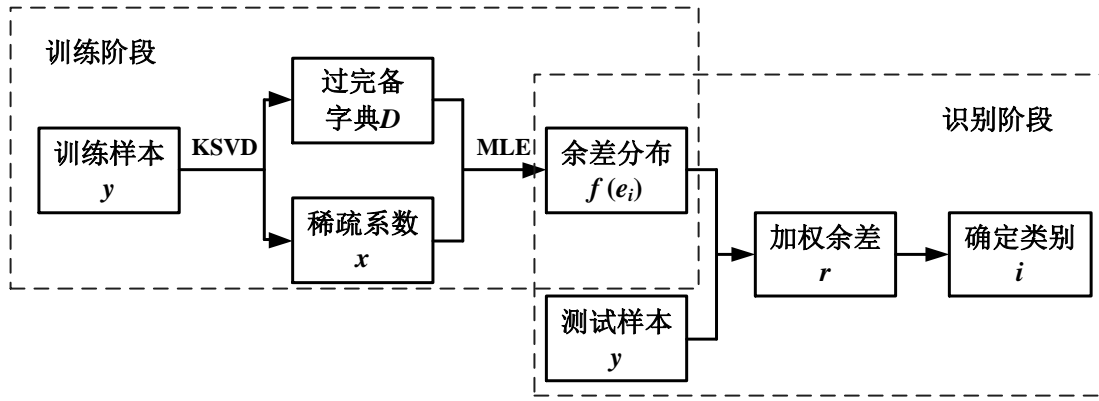


图 1-1 最大似然估计稀疏表示分类算法整体框图

Fig. 1-1 The diagram of Maximum likelihood sparse representation activity recognition algorithm

### 1.2.1 基于 K-SVD 优化设计过完备字典

K-SVD 是近年来提出的一种非常经典的字典训练算法，其基本思想是依据误差最小原则，对误差项进行 SVD 分解，选择使误差最小的分解项作为更新的字典原子和相应原子系数，经过不断的迭代从而得到优化的解。本研究为有效降低较大过完备字典对稀疏表示分类算法复杂度的影响，以及避免不同动作类别的相互干扰，提出基于动作类别的 K-SVD 优化设计过完备字典，减少冗余动作样本信息。假设包含所有动作类别的样本训练集表示为  $Y = [Y_1, Y_2, \dots, Y_k]$ ，其中  $k$  表示动作模式类别数量。每个动作类别相对应的子字典分别表示为  $D_1, D_2, \dots, D_k$ 。K-SVD 算法目标方程表示为：

$$\langle D_i, X_i \rangle = \arg \min \left\{ \|Y_i - D_i X_i\|_2^2 \right\} \quad s.t. \quad \forall j, \|x_j\|_0 \leq T_0 \quad (1-1)$$

式中， $i = 1, 2, \dots, k$ ， $T_0$  是一个常量。对于给定的训练样本集  $Y = \{y_i\}_{i=1}^L$ ，目标字典原子数  $K$  和收敛条件  $T_0$ 。

---

算法： K-SVD 字典学习算法

---

(1) 初始化字典  $D_i^{(0)} \in R^{m \times K}$ ，其每一列均已归一化处理。设置迭代次数  $J = 1$ 。

(2) 采用跟踪算法计算训练样本  $y_i$  的表示系数  $x_i$ ，并求解下列优化问题：

$$D_i = \arg \min \left\{ \|y_i - D_i x_i\|_2^2 \right\}, \quad s.t. \quad \|x_i\|_0 \leq T_0, \quad i = 1, 2, \dots, l$$

(3) 对字典  $D_i$  中每一列  $d_k$  ( $k = 1, 2, \dots, K$ )，更新方法如下：

a) 定义一组使用该字典原子的数据样本， $w_k = \{i \mid 1 \leq i \leq K, x_T^k(i) \neq 0\}$ ；

b) 计算误差矩阵， $E_k = Y - \sum_{j \neq k} d_j x_T^j$ ；

---

- 
- c) 根据  $E_k$  选择和  $w_k$  对应的列, 得到  $E_k^R$ ;
  - d) 对  $E_k^R$  进行 SVD 分解:  $E_k^R = U\Delta V^T$ 。将  $U$  的列设置为  $d_k$ 。并将  $V$  的第一列与  $\Delta(1,1)$  的乘积设置为  $x_R^k$ 。
- (4) 满足收敛条件则停止迭代, 否则设置  $J = J + 1$ , 转至步骤(2)。
- 

基于上述步骤, 可得到由每一动作类别的子字典级联而成的一个完整优化过完备字典  $D$ , 既可减少字典规模, 又可有效确保动作样本中的判别信息不丢失。

### 1.2.2 最大似然稀疏表示动作分类模型

基于所得优化过完备字典  $D$ , 可将测试样本  $y$  稀疏表示为:

$$y = Dx + \sigma \quad (1-2)$$

式中,  $\sigma$  表示为误差容限, 尽可能确保稀疏表示系数  $x = [0, \dots, 0, x_1, x_2, \dots, x_{n_i}, 0, \dots, 0]$ , 非零系数  $x_1, x_2, \dots, x_{n_i}$  是与测试样本  $y$  同类训练样本对应的系数。式(1-2)稀疏表示系数可通过下列极小化  $l_1$  范数求解。

$$\hat{x} = \arg \min \|x\|_1 \quad s.t. \quad \|y - Dx\|_2^2 \leq \sigma \quad (1-3)$$

式中, 约束条件要求余项  $e = y - Dx$  满足  $\|e\|_2 \leq \sigma$ 。为此, 基于最大似然估计理论将余项转化为最大似然分布函数, 构建最大似然稀疏表示动作分类模型。具体算法描述如下。

将字典  $D$  改写为  $D = [d_1; d_2; \dots; d_k]$ , 其中行向量  $d_i$  表示  $D$  的第  $i$  行。余项表示为  $e = [e_1; e_2; \dots; e_n]$ , 其中, 第  $i$  行  $e_i = y_i - d_i x$ ,  $i = 1, 2, \dots, n$ , 且假设  $e_1, e_2, \dots, e_n$  独立同分布, 其概率密度函数记作  $f_\theta(e_i)$ , 其中,  $\theta$  是特征参数。则余项的最大似然函数可表示为:  $-\ln L_\theta = \sum_{i=1}^n \rho_\theta(e_i)$ , 其中,  $\rho_\theta(e_i) = -\ln f_\theta(e_i)$ 。

在稀疏表示模型中, 系数  $x$  具有稀疏性约束。因此, 系数  $x$  的最大似然估计求解可以转化为式 (1-4)所示的最小优化问题。

$$\hat{x} = \arg \min \sum_{i=1}^n \rho_\theta(y_i - d_i x) \quad s.t. \quad \|x\|_1 \leq \sigma \quad (1-4)$$

一般来说, 余差  $e$  不符合高斯分布。但是, 可以假设余差  $e$  的概率密度函数  $f_\theta(e_i)$  具有高斯分布密度函数所具有的特性:  $f_\theta(e_i)$  是对称的, 并且当  $|e_i| < |e_j|$  时,  $f_\theta(e_i) > f_\theta(e_j)$ 。因此,  $\rho_\theta(e_i)$  具有以下特性:  $\rho_\theta(0)$  是全局最小值; 对称性, 即  $\rho_\theta(e_i) = \rho_\theta(-e_i)$ ; 单调性, 当  $|e_i| > |e_j|$  时,  $\rho_\theta(e_i) < \rho_\theta(e_j)$ 。

设  $F_\theta(e) = \sum_{i=1}^n \rho_\theta(e_i)$ , 并对  $F_\theta(e)$  在  $e = e_0$  处做一阶泰勒展开, 如式(1-5)。

$$\hat{F}_\theta(e) = F_\theta(e_0) + (e - e_0)^T F'_\theta(e_0) + R_1(e_0) \quad (1-5)$$

式中,  $R_1(e)$  为高阶余项。  $F'_\theta(e_0) = [\rho'_\theta(e_{0,1}); \rho'_\theta(e_{0,2}); \dots; \rho'_\theta(e_{0,n})]$ , 其中,  $e_{0,i} (i=1,2,\dots,n)$  表示  $e_0$  中的第  $i$  个元素。高阶余项  $R_1(e)$  的估计值可记作  $R_1(e) = 0.5(e - e_0)^T W (e - e_0)$ , 其中  $W$  是一个对角矩阵。因此,  $e$  中的所有元素都是相互独立的。  $F_\theta(e)$  在  $e=0$  达到最小值 0, 则当  $e=0$  时,  $\hat{F}'_\theta(e)$  也达到最小值。令  $\hat{F}'_\theta(e) = 0$ , 可以计算得到对角矩阵  $W$  对角元素值, 如式(1-6)。

$$W_{i,i} = \rho'_\theta(e_{0,i}) / e_{0,i} \quad (1-6)$$

根据函数  $\rho_\theta(e)$  的特性,  $\rho'_\theta(e_i)$  和  $e_i$  的正负符号相同, 所以对角矩阵  $W$  中的所有元素都是非负值。因此,  $\hat{F}_\theta(e)$  可以改写为  $\hat{F}_\theta(e) = 1/2 \|W^{1/2}e\|^2 + b$ ,  $b$  是一个由  $e_0$  决定的常数。式(1-1)可被改写为式(1-7)。

$$\hat{x} = \arg \min \|W^{1/2}(y - Dx)\|_2^2 \text{ s.t. } \|x\|_1 \leq \sigma \quad (1-7)$$

比较式(1-7)和式(1-3)可以看出, 最大似然稀疏表示分类方法就是一个加权的稀疏表示模型。由于权重矩阵  $W$  是一个对角矩阵,  $W_{i,i}$  是针对待测向量中每一个相应原子的权值, 对于差异性较为明显的原子值, 权重较大, 不具有差异性 or 差异性较小的原子值, 赋予的权重则小一些, 这样的操作对于分类效果的好处是显而易见的。考虑到上述特性, 选择与其相似的 SVM 算法中 *hinge loss* 函数<sup>[63]</sup>作为权重函数, 通过迭代优化, 直至收敛, 最终求得稀疏表示系数。

### 第三节 实验结果和分析

#### 1.3.1 实验数据及其预处理

本研究选用美国加州伯克利大学公开发布的包含多传感数据的人体动作模式数据库 WARD。该数据库采集 20 名受试者 (13 名男性, 7 名女性, 年龄在 19~70 岁) 13 种不同动作模式: 站立、坐、躺、向前走、向左转、向右转、上楼、下楼、慢跑、跳、推轮椅、顺时针走、逆时针走。每名受试者要求佩戴 5 个相同传感节点 (内嵌一个三轴加速度计传感器和一个二轴陀螺仪), 分别置于左手腕、右手腕、左足踝、右足踝、腰部。采样率设置为 30Hz。本研究选用上述前 11 种动作模式数据验证本章所提算法有效性。

为确保所选动作模式数据信息完整性, 本章采用滑动窗口方法截取数据段, 窗口长度设置为 200 点。选用三个方向的加速度数据和二个方向的陀螺仪数据定义采样数据向量维数为  $m=1000$ 。采用五阶平滑滤波对所选样本数据消噪。

为客观评价本章所提算法的分类性能, 我们采用留一交叉验证法, 即从所有 20

名受试者（每名受试者每种动作取 5 个样本）任意选取 19 名受试者数据作为训练样本集，剩余 1 名受试者作为测试样本。为确保动作样本训练、测试的可靠性，上述交叉验证任意重复 75 次，取最终平均结果作为分类器的识别率。

### 1.3.2 优化设计过完备字典

由于样本数据维数为  $m=1000$ ，含一些冗余信息，影响优化过完备字典的获取和分类器的最优性能。在实验中，我们采用随机投影方法压缩数据，降低样本数据冗余信息。压缩率（compressive proportion,  $cp$ ）的定义如式(1-8)。

$$cp = m'/m \quad (1-8)$$

式中， $m'$  表示压缩数据长度。我们在原始数据维度为  $m=1000$  及优化过完备字典大小取 40 状况下，选择最优压缩率  $cp$  值。本章所提算法基于不同压缩率所获得的识别率和运行时间如表 1-1 所示。从表 1-1 可以看到，识别率和运行时间均随压缩率的增大而增大，但压缩率为 0.5 时能够获得与压缩率为 1 时几乎相同的最大识别率，运行时间却明显减少（约 7.2 秒）。这些结果表明，最优压缩率为 0.5。因为当  $cp=0.5$  时，压缩数据不仅可包含与原始数据几乎相同的动作模式差异信息，同时可以有效降低本章所提算法复杂度，提高动作分类性能。

表 1-1 本章算法基于不同压缩率的识别率和运行时间

Tab. 1-1 The accuracy and runtime of the proposed algorithm based on different compressive

proportion		
压缩率( $cp$ )	识别率(%)	运行时间(s)
0.05	86.91	4.76
0.1	93.45	5.90
0.2	94.18	6.97
0.5	95.45	10.75
1	95.82	17.99

在选取最优压缩率为 0.5 状况下，我们进一步评估了基于本章所提算法选取优化过完备字典对动作分类性能的影响。实验中，每种动作训练样本数量选取为 95。图 1-2 给出了选取不同字典对动作分类性能的影响结果。从图 1-2 可以看到，本章所提算法随选取字典大小变化而变化。当选取字典大小从 10 增加到 40 时，动作识别率上升至最大（约 95%）；其后，识别率呈下降趋势。这些结果表明，字典规模过

小，难以包含动作模式完整差异信息；字典规模过大，所选样本数据必含过多冗余信息，两者均影响动作分类性能。但通过优化学习选取规模适当字典，既可包含动作模式完整差异信息，又可降低样本数据冗余信息，有效提高动作模式分类性能。




图 1-2 基于不同字典大小的识别率变化结果

Fig. 1-2 The accuracy based on different dictionary size

### 1.3.3 最大似然稀疏表示动作分类性能

实验中，我们选取传统的近紧邻算法（NN）、稀疏表示分类算法（SRC）、基于 K-SVD 的稀疏表示分类算法（KSVD+SRC），作为比较，进一步客观评价本章所提算法（KSVD+MLE）的有效性。最优字典选取为 40，其比较结果如图 1-3 所示。从图 1-3 可以看到，四种动作分类算法动作识别率均随数据维度增长而增长，比较而言，本章所提算法（KSVD+MLE）可获得最大识别率（96.36%），分类性能明显优于其他所选三种分类算法性能，NN 动作分类性能最差。这些结果表明，本章所提最大似然稀疏表示模型能够准确估计动作模式稀疏表示系数残差，有效提高动作模式分类性能。此外，从图 1-3 中我们观察到，基于 SRC 的动作分类性能（识别率为 92.27%）明显优于基于 KSVD+SRC 的动作分类性能（83.64%），原因是 K-SVD 优化字典难以为 SRC 算法提供精确的稀疏表示系数残差，影响其分类性能。




图 1-3 基于不同动作分类算法的比较结果

Fig. 1-3 The comparison result based on different activity recognition algorithms

此外，在实验中，我们基于最优选取字典以及最优压缩率，验证本章所提算法对所选 11 种动作模式分类性能，进一步评估本章所提算法对连续动作模式分类有效性。其分类混淆矩阵如表 1-2 所示。从表 1-2 可以看到，本章所提算法对 11 种不同动作模式识别率均达到 94%以上，平均识别率高达 96%以上。特别是，站立、躺、左转、右转等动作识别率均可高达 98%以上。作为对比，SRC 算法对所选 11 种动作模式的分类混淆矩阵如表 1-3 显示。从表 1-3 可以看出，SRC 算法对坐、上楼、下楼、推轮椅四种动作模式识别率均在 90%以下，平均识别率仅为 92%，比之本章所提算法平均识别率低 4%。综上，本章所提算法能够准确估计动作模式稀疏表示系数残差分布，可有效识别动作模式连续变化。

表 1-2 本章所提算法基于 11 种动作信号的分类混淆矩阵

Tab. 1-2 The confusion matrix of SRC based on 11 kinds of activity signals

动作类别	站立	坐	躺	向前走	左转	右转	上楼	下楼	慢跑	跳	推轮椅	识别率
站立	370	4	0	0	0	0	1	0	0	0	0	0.99
坐	8	361	3	0	2	0	0	0	0	0	1	0.96
躺	0	0	375	0	0	0	0	0	0	0	0	1.00
向前走	4	0	0	357	4	0	5	2	0	1	2	0.95
左转	1	0	0	0	374	0	0	0	0	0	0	0.99
右转	5	0	0	0	0	369	0	0	0	0	1	0.98
上楼	2	0	0	5	2	0	356	2	7	0	1	0.95

下楼	13	1	0	0	0	0	1	352	4	0	4	0.94
慢跑	7	0	0	0	0	0	5	0	361	2	0	0.96
跳	11	0	0	0	0	0	0	2	2	360	0	0.96
推轮椅	2	16	0	0	0	0	0	0	0	0	357	0.95
召回率	0.87	0.945	0.99	0.99	0.98	1.00	0.97	0.98	0.97	0.99	0.98	

表 1-3 SRC 算法基于 11 种动作信号分类混淆矩阵

Tab. 1-3 The confusion matrix of SRC based on 11 kinds of activity signals

动作类别	站立	坐	躺	向前走	左转	右转	上楼	下楼	慢跑	跳	推轮椅	识别率
站立	353	13	0	4	1	2	0	0	0	1	1	0.94
坐	20	334	15	0	2	0	0	0	0	0	6	0.89
躺	0	4	371	0	0	0	0	0	0	0	0	0.99
向前走	11	1	0	343	10	8	1	0	0	0	1	0.91
左转	6	0	0	0	369	0	0	0	0	0	0	0.98
右转	3	0	0	0	0	369	0	0	0	0	3	0.98
上楼	5	0	0	5	6	3	333	2	8	0	13	0.88
下楼	11	4	0	3	1	0	17	320	9	0	10	0.85
慢跑	13	0	0	0	0	0	10	1	347	4	0	0.96
跳	15	1	0	0	0	2	1	1	6	349	0	0.93
推轮椅	7	37	0	3	0	3	0	2	0	0	323	0.86
召回率	0.80	0.85	0.99	0.96	0.95	0.95	0.92	0.98	0.94	0.99	0.90	

#### 第四节 本章小结

本章提出了一种基于 K-SVD 的最大似然稀疏表示动作分类算法。该算法可有效利用 K-SVD 优化学习算法，将不同动作模式训练样本按其所属类别分组优化训练，避免各类样本数据训练时相互干扰，将不同动作模式类别所属的子字典拼合一个完整字典，准确稀疏表示测试样本，使最大似然稀疏模型准确估计稀疏表示系数残差，有效提高动作模式分类性能，有助于判别动作模式连续变化。



## 第二章 基于 D-KSVD 的联合稀疏表示动作识别算法

### 第一节 引言

为了有效提升多传感器节点体域网动作模式识别性能，本章提出了一种基于 D-KSVD 的联合稀疏表示动作识别新算法。其基本思想是：首先基于改进 D-KSVD 算法训练过完备字典，为避免不同类别动作样本相互干扰，训练样本分类训练得到分属不同类别的初始子字典，再级联构建初始总字典，然后引入标签信息和罚因子，并迭代更新字典，获得判别性过完备字典和相应的分类器，随后采用联合稀疏表示算法获取测试样本稀疏表示系数，最后通过分类器得到测试样本对应的标签信息，并判别测试样本所属类别。本研究选取 WARD 作为人体动作数据源验证本章所提算法的有效性。与传统基于稀疏表示的模式识别算法相比，本章所提算法能够获得具有更高判别性的过完备字典，并充分挖掘多传感器所记录动作信号之间的时空相关性，有效提高体域网动作模式识别性能。

### 第二节 基于 D-KSVD 的联合稀疏表示动作分类算法

本章所提算法旨在综合 D-KSVD 字典训练算法和联合稀疏表示分类算法两者的优势，优化设计过完备字典，并采用联合稀疏表示算法估算测试样本对应的稀疏表示系数，再利用分类器和稀疏表示系数判定测试样本所属类别，算法具体流程如图 2-1 所示。

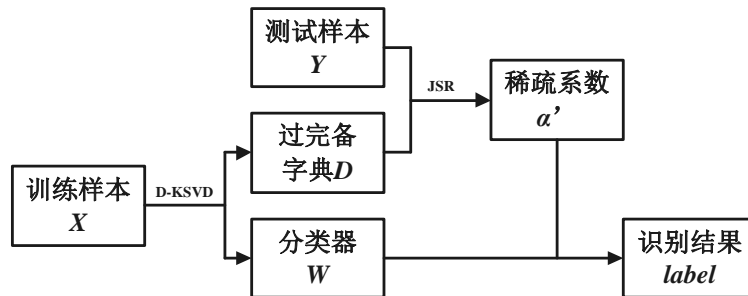


图 2-1 基于 D-KSVD 的联合稀疏表示动作识别算法框架图

Fig. 2-1 The diagram of joint sparse representation activity recognition algorithm based on D-KSVD

在初始化阶段，分属不同类别的动作样本集合分别基于 K-SVD 算法优化学习，得到分属各类的初始子字典，再将所有初始子字典级联构成初始化总字典，并引入标签信息，迭代更新直至获取最终的过完备字典和相应的分类器，随后基于联合稀疏表示算法求解测试样本的稀疏表示系数，最后基于分类器和联合稀疏表示系数获取测试样本对应的标签信息，判别其所属类别。

### 2.2.1 改进 D-KSVD 字典训练

K-SVD 算法旨在利用更少的数据包含更多有效识别信息，其目标方程如式(2-1)。

$$\langle D, \alpha \rangle = \arg \min \|X - D * \alpha\|_2 \quad s.t. \quad \|\alpha\|_0 \leq T \quad (2-1)$$

式中， $X$  表示动作模式训练样本集合， $D$  表示过完备字典， $\alpha$  表示稀疏表示系数， $T$  是一个常数。式(2-1)中仅考虑重构误差和表示系数的稀疏性，经过训练所得过完备字典可能缺乏必要的判别性。为此，可在训练过程中引入标签和罚因子，如式(2-2)。

$$\langle W, \alpha \rangle = \arg \min \|L - W * \alpha\|_2 + \beta \|W\|_2 \quad (2-2)$$

式中， $\beta$  是一个常数， $W$  是线性分类器  $L = W * \alpha$  中的参数项， $L$  表示标签矩阵，其第  $i$  列定义为： $L_i = [0, 0, \dots, 1, \dots, 0, 0]^T$ ，其中仅包含一个非零元素，该非零元素所在位置即可被记作训练样本所属类别。 $\|L - W * \alpha\|_2$  表示分类误差， $\|W\|_2$  可视为罚因子。综合考虑式(2-1)和式(2-2)，得到兼顾重构误差、表示系数、类别信息的字典训练方法，其目标方程如式(2-3)。

$$\langle D, W, \alpha \rangle = \arg \min \|X - D * \alpha\|_2 + \gamma * \|L - W * \alpha\|_2 + \beta * \|W\|_2 \quad s.t. \quad \|\alpha\|_0 \leq T \quad (2-3)$$

式中， $\beta$  和  $\gamma$  都是常数，分别表示分类误差和罚因子的权重。在式(2-3)求解过程中，字典  $D$  和分类器  $W$  需逐步迭代更新，计算结果可能陷入局部优化解。因此，式(2-3)可改写为式(2-4)。

$$\langle D, W, \alpha \rangle = \arg \min \left\| \begin{pmatrix} X \\ \sqrt{\gamma} * L \end{pmatrix} - \begin{pmatrix} D \\ \sqrt{\gamma} * W \end{pmatrix} * \alpha \right\|_2 \quad s.t. \quad \|\alpha\|_0 \leq T \quad (2-4)$$

式中，矩阵  $\begin{pmatrix} D \\ \sqrt{\gamma} * W \end{pmatrix}$  在运算过程中需逐列归一化，常系数  $\gamma$  通常设置为 1。字典训练结束后，字典  $D$  和分类器  $W$  需要再次逐列进行归一化，具体计算过程如式(2-5)。

$$\begin{aligned} D' &= \{d'_1, d'_2, \dots, d'_n\} = \left\{ \frac{d_1}{\|d_1\|_2}, \frac{d_2}{\|d_2\|_2}, \dots, \frac{d_n}{\|d_n\|_2} \right\} \\ W' &= \{w'_1, w'_2, \dots, w'_n\} = \left\{ \frac{w_1}{\|w_1\|_2}, \frac{w_2}{\|w_2\|_2}, \dots, \frac{w_n}{\|w_n\|_2} \right\} \end{aligned} \quad (2-5)$$

式中,  $d_i$  和  $w_i$  分别表示字典  $D$  和分类器  $W$  的第  $i$  列。上述字典训练过程如图 2-2 所示。其中训练样本不分类别地统一训练, 虽然步骤较少, 但不同类别样本中所含有的信息在训练过程中不可避免地互相干扰, 从而削弱过完备字典  $D$  的判别性。为此, 本章对该算法做出改进, 在字典的初始化阶段, 分类训练动作样本集获得分属各类的初始子字典  $D_i$ , 初始字典由初始子字典直接拼合构成, 具体流程如图 2-3 所示。

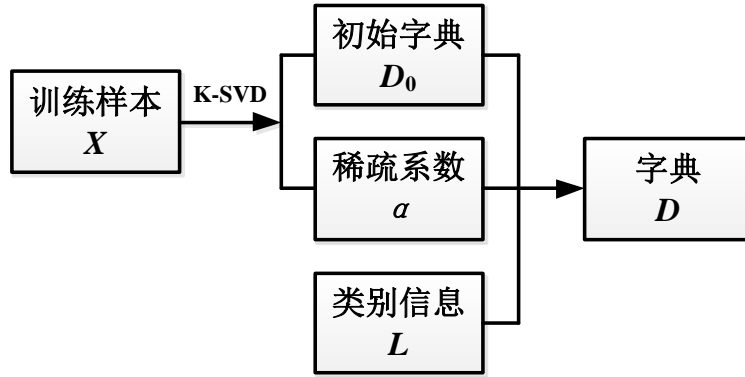


图 2-2 原始 D-KSVD 算法示意图

Fig. 2-2 The diagram of original D-KSVD algorithm

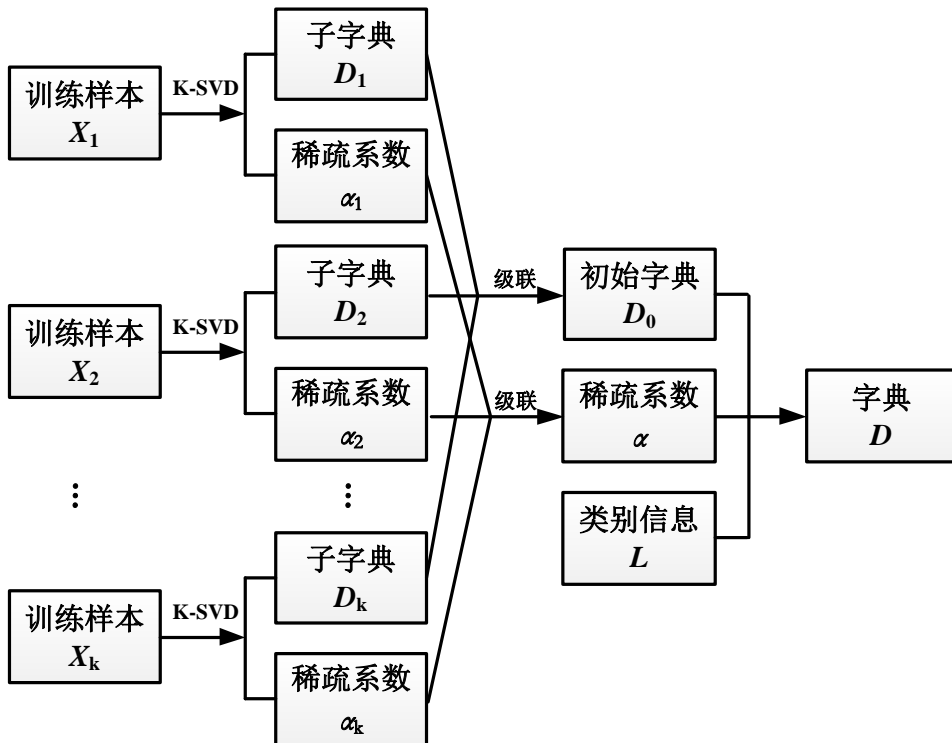


图 2-3 改进后的 D-KSVD 算法示意图

Fig. 2-3 The diagram of modified D-KSVD algorithm

图 2-3 中所示子字典  $D_i$  和稀疏系数  $\alpha_i$  的级联方式略有不同。子字典  $D_i$  的级联方式是  $D = [D_1, D_2, \dots, D_k]$ ；而稀疏系数  $\alpha_i$  采取对角方式级联，具体如式(2-6)。

$$\alpha = \begin{bmatrix} \alpha_1, \mathbf{0}, \dots, \mathbf{0} \\ \mathbf{0}, \alpha_2, \dots, \mathbf{0} \\ \dots \\ \mathbf{0}, \mathbf{0}, \dots, \alpha_k \end{bmatrix} \quad (2-6)$$

式中， $\mathbf{0}$  表示与  $\alpha_i$  ( $i=1, 2, \dots, k$ ) 具有相同维度的零矩阵。改进算法的优势在于将训练样本分类训练，能够避免来自其他类别样本的干扰，有效降低过完备字典所含误差。

### 2.2.2 联合稀疏表示分类算法

假设采集节点  $j$  所记录的第  $i$  类动作训练样本集记作  $X_i^j = [x_i^j, x_i^j, \dots, x_{i,n_i}^j] \in R^{m \times n_i}$ ，则属于第  $i$  类别人体动作测试样本  $y_i^j \in R^m$  都可以被  $X_i^j$  线性表示，如式(2-7)。

$$y_i^j = X_i^j * \alpha_i^j = x_{i,1}^j * \alpha_{i,1}^j + x_{i,2}^j * \alpha_{i,2}^j + \dots + x_{i,n_i}^j * \alpha_{i,n_i}^j \quad (2-7)$$

式中， $X^j = [X_1^j, X_2^j, \dots, X_k^j] = [x_{1,1}^j, x_{1,2}^j, \dots, x_{k,n_k}^j]$  表示所有训练样本所构成的集合， $\alpha_i^j = [\alpha_{i,1}^j, \alpha_{i,2}^j, \dots, \alpha_{i,n_i}^j]$  表示常数向量。测试样本  $y^j$  可以由  $X^j$  线性表示，如式(2-8)。

$$y^j = x_{1,1}^j * \alpha_{1,1}^j + x_{1,2}^j * \alpha_{1,2}^j + \dots + x_{k,n_k}^j * \alpha_{k,n_k}^j = X^j * \alpha^j \quad (2-8)$$

式中， $X^j$  可以被视作过完备字典。 $\alpha^j = [0, \dots, 0, \alpha_{i,1}^j, \alpha_{i,2}^j, \dots, \alpha_{i,n_i}^j, 0, \dots, 0]$  为常数向量，具有一定的稀疏性。向量  $\alpha^j$  所有元素中，与  $y^j$  属于同一类的训练样本对应位置元素为非零元素，其余元素均为零。当  $X^j$  满足 *RIP* 条件时， $y^j$  的稀疏表示系数求解可以转化为式(2-9)所示  $l_1$  范数优化问题。

$$\hat{\alpha}^j = \arg \min \|\alpha^j\|_1 \quad s.t. \quad \|y^j - X^j \alpha^j\|_2 \leq \varepsilon^j \quad (2-9)$$

式中， $\varepsilon^j \in R^m$  表示采集节点  $j$  在采集过程中所产生的噪音信息。式(2-9)仅考虑到一个传感器节点的情况，将多个采集节点记录的同一类别动作信号联合构建联合决策模型。如果将处理不同传感器节点收集的动作样本看作是独立任务，则基于多传感器加速度动作信号的稀疏表示问题可以归纳为：

$$\{\hat{\alpha}\}_{j=1}^J = \arg \min \sum_{i=1}^J \|y^j - X^j \alpha^j\|_2 \quad s.t. \quad \|\alpha^j\|_0 \leq T_0 \quad (2-10)$$

式中， $J$  表示采集节点总数目， $T_0$  表示系数  $\alpha^j$  稀疏性，是一个常数。式(2-10)依旧将基于多传感器节点加速度动作信号看作是相互独立的数据，无法挖掘多传感器节点加速度数据之间存在的关联特征。根据 JSM-2 (Joint Sparse Model 2) 模型<sup>[64]</sup>，当多个稀疏表示向量共享相同稀疏支撑集，仅有稀疏项取值不同时，可以将基于多传感器

加速度动作样本稀疏系数求解可转化为式(2-11)所示联合优化问题。

$$\hat{\alpha} = \arg \min \|Y - X\alpha\|_F^2 \quad s.t. \quad \|\alpha\|_{l_0 \setminus l_1} \leq T_0 \quad (2-11)$$

式中,  $X$  表示所有传感器节点记录的动作数据集合,  $\|\alpha\|_{l_0 \setminus l_2}$  表示稀疏表示系数矩阵的混合范数, 即计算矩阵  $\alpha$  的每一行  $l_2$  范数后, 再计算其结果矩阵的  $l_0$  范数, 具体计算方法如式(2-12)。

$$\|\alpha\|_{l_0 \setminus l_2} = \left\| \left[ \|\alpha(1,:)\|_{l_2}, \|\alpha(2,:)\|_{l_2}, \dots, \|\alpha(J,:)\|_{l_2} \right] \right\|_{l_0} \quad (2-12)$$

假设基于训练样本集  $X$  经改进后的 D-KSVD 算法训练所得过完别字典记作  $D$ , 则式(2-11)可改写成式(2-13)所示联合稀疏表示分类问题。

$$\alpha' = \arg \min \|Y - D\alpha\|_F^2 \quad s.t. \quad \|\alpha\|_{l_0 \setminus l_2} \leq T_0 \quad (2-13)$$

目前, 联合重构问题常用求解算法有 OSGA、SOMP<sup>[65]</sup>和 DCS-SAMP<sup>[66]</sup>等, 本文采用多任务贝叶斯压缩感知算法 (Multitask Bayesian Compressive Sensing, MT-BCS)<sup>[67]</sup>算法。获取稀疏表示系数后, 测试样本识别结果取决于其对应表示系数  $\alpha'$  和分类器  $W'$ , 如式(2-14)。

$$label = W' * \alpha' \quad (2-14)$$

式中,  $label$  表示一个向量, 其中各元素值可以看作测试样本  $y$  与各动作类别的相似度比重。理想状态下,  $label$  的最终形式应为  $\{0, 0, \dots, 1, \dots, 0\}$ , 即标签向量所有元素中有且仅有一个非零元素, 而该非零元素所在位置对应的动作类别, 即是测试样本所属类别。实际上,  $label$  中所有元素都可能都是非零值, 我们取绝对值最大的元素所在位置序号作为测试样本所属类别。

## 第三节 实验结果和分析

### 2.3.1 实验数据及预处理

本研究采用公开发布的可穿戴动作识别数据库 WARD 作为实验数据。该数据库共计包含 20 名测试者 (13 名男性, 7 名女性, 年龄处于 19~70 岁之间) 13 种日常动作数据。每名测试者佩戴 5 个传感器 (内嵌一个 3 轴加速度传感器和一个 2 轴陀螺仪), 分别置于测试者的左、右手腕, 左、右脚踝和腰部, 节点采集频率为 30Hz。为验证本章所提算法的有效性, 我们选取其中常见的 10 种动作模式: 站、坐、躺、向前走、向左转、向右转、上楼、下楼、慢跑和跳, 每一种动作类别每个受试者分别提取 10 个动作样本。每一次实验随机选取每一个动作类别中的 100 个动作数据

(20 名测试者, 每人 5 个) 作为训练样本, 另外 100 个样本作测试样本, 重复实验 13 次, 最终的动作识别率取 13 次实验结果的平均值。

为保证所选动作信号的完整性, 实验采用滑动窗口方法截取数据段, 窗口长度设置为 200 点。选用 3 个方向的加速度数据和 2 个方向的陀螺仪数据, 共 5 项数据定义动作样本, 其维度为  $m=1000$ , 并采用五阶平滑滤波对所选动作样本消噪。实验采用随机投影方法压缩原始动作样本, 减少其中所含冗余信息。压缩率 (Compression Rate,  $CR$ ) 是指随机投影算法对初始动作样本的压缩程度, 其定义如式(2-15)。

$$CR = n / m \quad (2-15)$$

式中,  $m$  表示初始动作样本维度,  $n$  表示压缩后动作样本维度。本章中, 动作样本初始维度为  $m=1000$ , 压缩后维度范围为  $100 \sim 1000$ ,  $CR$  取值范围为  $[0.1, 1]$ 。

### 2.3.2 实验结果及分析

图 2-4 显示了动作类别向右走在字典训练过程中产生的总误差, 从图中可以看出, 总误差值一直处于较低的水平, 且随着迭代次数增多, 误差值呈递减趋势, 并逐渐趋于平稳。由此可见, KSVD 算法适用于训练体域网人体动作样本。后续实验中, 字典训练的迭代次数均取 20。




图 2-4 动作向右走字典训练的总误差

Fig. 2-4 The total error of Walking right-circle in dictionary training

为客观评价本章所提算法在动作识别率以及时间复杂度两方面的优势, 我们选择基于 K-SVD 的稀疏表示分类算法 (KSVD+SRC) 作为比较, 比较结果如图 2-5 所示。从图 2-5(a)中可以看出, KSVD+SRC 算法的识别率随着字典大小 (此处字典大

小指的是每个类别动作样本训练获取的字典大小)的增长而上升,最高达到 90%以上。而本章所提算法(DKSVD+JSRC)的识别率在字典大小处于 40 到 60 范围内能够达到最高,超过 96%,相对于参照算法具有明显优势。图 2-5(b)显示了两种算法基于不同规模的字典识别 1000 个测试样本消耗的总时间,从图中可以看出,本章所提算法同样具有明显优势,消耗的时间最少仅为 6.5 秒,最多 10.5 秒。而相同条件下,KSVD+SRC 算法消耗时间最少为 49 秒,最多达到 92 秒。该现象主要原因可能在于 KSVD+SRC 算法需通过求解  $l_1$  范式优化问题获取测试样本的稀疏表示余差并判别所属类别,本章所提算法基于分类器和联合稀疏表示系数获取识别结果,计算更加简便,可大幅节省动作识别时间。




图 2-5 两种算法的性能比较。(a) 基于不同字典大小的识别率;  
(b) 基于不同字典大小的识别时间

Fig. 2-5 The comparison of 2 algorithms. (a) The accuracy based on different dictionary sizes; (b) The recognition time based on different dictionary sizes

为进一步验证本章所提算法有效性,我们比较三种算法(包括 KSVD + SRC、DKSVD + JSRC 和 SRC)基于不同压缩率获取的动作模式识别率,比较结果如图 2-6 所示,图中  $d$  表示字典大小。从图中可以看出,三种算法动作识别率都随着动作样本维度的增加( $CR$  取值越高,压缩后样本维度越大)而上升,本章所提算法动作识别率最高, SRC 算法次之, KSVD + SRC 算法识别率最低。因为联合稀疏表示算法能够充分利用多传感器动作信号之间存在的时空相关性,相比于 SRC 算法能够更加准确地表示动作测试样本。而 D-KSVD 在字典训练过程中加入标签信息和罚因子后,经过学习所得完备字典所包含判别性信息明显多于 KSVD 算法基于原始动作样本训练所得完备字典。因此,本章所提算法取得高于 K-SVD + SRC 和 SRC 两种算法的动作识别率。




图 2-6 基于不同分类算法的平均识别率

Fig. 2-6 The average accuracy based on different classification algorithms

图 2-7 显示了坐和慢跑两种动作模式样本通过本章所提算法获得的联合稀疏表示系数和相似度比重（绝对值）。从图 2-7(a)显示了某一动作样本的稀疏表示系数，其中非零元素很少，取值最大的系数落于 $[50, 100]$ 频次区间内，对应的是第二种动作类别——坐。相应地，图 2-7(c)显示，该动作样本与第二类动作类别的相似度最高。图 2-7(b) 显示另一个动作样本的稀疏表示系数，其中非零元素几乎都落于 $[400, 450]$ 频次区间内，对应的正是第九种动作类别——慢跑。相应地，图 2-7(d)显示该样本与所有十种动作模式的相似度比重，其中与第九类动作类别的相似度最高。这些实验结果表明，所提算法可以基于具有判别性的过完备字典准确表示动作测试样本，准确识别人体动作模式。

表 2-1 显示了本章所提算法基于十种不同动作模式，在压缩率取 0.5，字典大小取 50 的情况下所得混淆矩阵。由表中数据可以看出，本章所提算法能够有效区分各种不同动作类别，十种不同动作模式识别率均达到 93%以上，其中躺、向左走、向右走、上楼和下楼等动作识别率超过 97%，整体平均识别率达到 96%以上。由此可见，本章所提算法具有较强的相似动作区分能力，原因在于联合稀疏表示分类算法能够有效利用不同传感器所记录动作数据之间存在的时空相关性，提取出更深层、更具有判别性的数据特征，从而有效避免误识。综上所述，本章所提算法能够准确重构动作模式测试样本，有效提高多传感器节点动作模式识别性能。






图 2-7 动作坐和慢跑的稀疏系数和相似度比重。(a)动作坐的稀疏系数；(b)动作慢跑的稀疏系数；(c)动作坐的相似度比重；(d)动作慢跑的相似度比重

Fig. 2-7 The sparse coefficients and similarity weights of Sitting and Jog. (a) The sparse coefficients of Sitting; (b) The sparse coefficients of Jog; (c) The similarity weights of Sitting; (d) The similarity weights of Jog

表 2-1 本章所提算法基于 10 种动作样本的混淆矩阵

Tab. 2-1 The confusion matrix of the proposed algorithm based on 10 activities

类别	站	坐	躺	向前走	向左走	向右走	上楼	下楼	慢跑	跳	识别率(%)
站	1218	58	0	2	7	0	0	2	13	0	93.69
坐	73	1224	0	0	0	1	0	2	0	0	94.15
躺	0	2	1298	0	0	0	0	0	0	0	99.85
向前走	53	0	0	1219	0	1	0	0	26	1	93.77
向左走	21	0	0	0	1279	0	0	0	0	0	98.38
向右走	29	0	0	0	0	1271	0	0	0	0	97.77
上楼	3	0	0	0	0	0	1271	0	26	0	97.77
下楼	29	0	0	0	0	0	0	1245	26	0	95.77
慢跑	0	0	0	0	0	0	0	0	1300	0	100
跳	37	0	0	0	0	0	0	0	13	1250	96.15
召回率(%)	83.25	95.33	100	99.84	99.46	99.84	100	99.68	92.59	99.92	

## 第四节 本章讨论

实验结果表明,本章所提算法在经过字典学习后,能够获得规模较小且具有良好的判别性的过完备字典,并基于过完备字典构建联合稀疏表示动作模式分类模型,充分发掘多传感器加速度动作信号之间存在的时空相关性,有效地提高基于多传感器节点的人体动作模式识别性能。基于过完备字典构建联合稀疏表示动作分类模型,其中最为关键一点在于如何优化设计具有良好判别性的过完备字典,本章所提算法尝试基于大量高维动作样本采用改进 D-KSVD 字典优化算法优化设计过完备字典。不同于原始 D-KSVD 算法中不分类别地统一训练所有样本,在本章所提算法初始化阶段,不同类别训练样本被分开训练得到分属各类的初始子字典,可以避免不同类别样本互相干扰,有效提升过完备字典判别性能。随后再引入判别信息(类别信息和罚因子),不断迭代更新直到获得判别性过完备字典。相较而言,KSVD+SRC 算法在字典训练过程中并没有引入判别信息,仅仅是基于训练动作样本所得过完备字典的判别性不足。SRC 算法所采用过完备字典仅由原始训练动作样本直接构成,没有经过优化设计,且字典规模偏大,导致字典包含过多冗余信息,判别性能较弱。由图 2-6 所示实验结果可以看出,本章所提算法动作识别率明显优于 KSVD + SRC 算法和 SRC 算法。

此外,基于多传感器加速度数据探讨人体动作模式分类问题的另一关键点在于如何充分利用多传感器加速度数据之间存在的时空相关性。本章所提算法基于多传感器节点动作数据,采用联合基于稀疏表示分类算法,充分有效挖掘多传感器动作数据之间存在的时空相关性,与传统稀疏表示动作分类算法相比较,能够更加准确地表示测试样本,有效提升体域网动作模式识别性能。而 SRC 算法将所有动作样本看作相互独立变量,无法有效利用多传感器动作数据之间存在的关联特性,仅通过求解  $l_1$  或  $l_2$  范数优化问题分别获得各传感器节点所采集动作数据所对应稀疏表示系数,并依此判别测试样本所属类别。同理,KSVD+SRC 算法中虽然采用优化字典,但是识别性能不升反降,可能是因为优化字典无法为 SRC 算法提供精确的稀疏表示系数余差,影响其分类性能。由图 2-7 所示实验结果可以看出,本章所提算法能够精确表示测试样本,经计算所得稀疏表示系数具有更加明显的稀疏性,且非零元素较为集中,有助于快速、准确判定测试样本所属类别。有别于传统稀疏表示分类算法基于最小残差逼近原则,选取表示残差最小的动作类别作为测试样本所属类别,本章算法采用相似度比重作为动作样本类别的判别标准,更加直观简洁。

## 第五节 本章小结

本章提出了一种基于 D-KSVD 算法的联合稀疏表示人体动作识别算法。该算法基于改进 D-KSVD 算法优化字典，有机融合多传感器体域网动作数据样本，通过联合稀疏表示算法发掘更多人体动作模式之间的时空相关性信息，采用联合重构准确获取测试样本所对应联合稀疏表示系数，并依此判别测试样本所属类别，能够有效提高人体动作识别性能，为进一步构建基于多传感器体域网人体动作识别的稀疏表示分类算法提供新的思路。下一步的工作主要基于本研究成果，优化过完备字典设计方法，探索更加高效的联合稀疏表示算法发掘多传感器动作数据之间存在的时空相关性，进一步提升多传感器体域网动作模式识别性能。



## 第三章 一种快速鲁棒协作表示动作分类算法

### 第一节 引言

近年来,一种新兴的协作表示分类 (Collaborative Representation Classification, CRC)[68-70]算法在人脸识别、图像处理等研究领域得到广泛关注。该算法可以利用少量样本内在相似性,协作表示测试样本,通过求解范式优化问题来获得测试样本协作表示系数,定义正则化残差样本判别规则,寻找样本类别的差异性,准确判别测试样本所属类别。从理论上分析,是分类算法能够有效发挥协作表示机制优越性,从少量样本数据结构中获取更多与样本类别信息密切相关性信息,可避免稀疏表示分类算法搞复杂度的问题,显著提高体域网动作模式分类性能。为综合解决基于体域网实时监测人体动作变化研究中识别算法复杂度较高和功耗偏高等问题,本章结合最近邻思想和协作表示分类算法,提出了一种快速鲁棒性协作表示动作分类 (fast robust collaborative representation classification, FRCRC)算法,其基本思路是:首先基于最近邻原则为待定测试样本寻找一定数量的近邻类别和近邻训练样本,重新构造训练样本集,然后基于该训练样本集构建快速鲁棒协作表示动作分类模型,通过扩展拉格朗日乘数 (augmented Lagrange multiplier, ALM)算法<sup>[71-72]</sup>求解待定测试样本协作表示系数和表示残差,判定该测试样本所属类别。本研究采用 WARD 数据库验证本章所提算法识别性能。与传统稀疏表示动作分类算法相比,本章所提算法通过协作表示机制准确获取待定测试样本的表示系数和表示残差,显著提升体域网动作模式识别率,同时降低算法体域网动作模式识别算法时间复杂度。

### 第二节 快速鲁棒协作表示动作分类算法

本章所提 FRCRC 算法旨在基于最近邻原则从大量训练样本中寻找测试样本密切相关的近邻类别和近邻样本,构建近邻样本训练集,协作表示测试样本,通过准确求解协作表示系数和残差,鉴别动作模式类别,算法完整流程如图 3-1 所示。首先,通过计算样本中心点与测试样本的欧氏距离,选取与测试样本较近的动作类别作为近邻类别,并从每一个近邻类别所包含动作样本中选取一定数量近邻样本构建训练集。然后基于所选训练集构建快速鲁棒协作表示动作分类模型,求解测试样本

表示系数和表示残差，并判定测试样本所属类别。

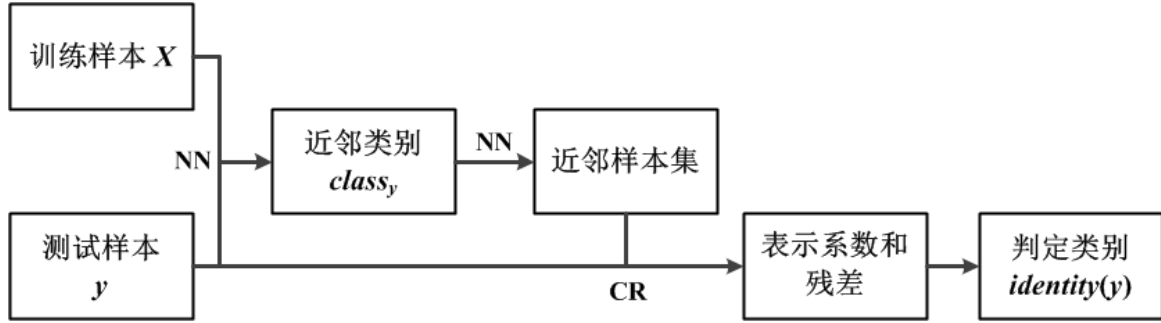


图 3-1 快速鲁棒协作表示动作识别算法框图

Fig. 3-1 The diagram of fast robust collaborative representation activity recognition algorithm

### 3.2.1 基于最近邻原则重新构建训练样本集

稀疏表示动作分类算法均是直接将所有训练样本级联构建过完备字典，再基于该字典求解测试样本表示系数，但该过程忽略了过完备字典规模过大（有大量高维动作样本构成）所导致计算开销过大的问题。此外，不加甄选地将所有训练样本用于表示测试样本，其中含有大量冗余信息对判定测试样本所属类别具有负面影响，导致动作识别率较低。本章基于最近邻原则（本章采用欧氏距离衡量不同动作样本之间的远近关系，且不同动作样本相似程度与样本之间的欧式距离大小成反比，即距离越小则相似度越高，反之亦然）选取测试样本的近邻类别和近邻样本，构建该测试样本特定训练样本集，减少相似度较低动作类别对于测试样本的干扰，同时降低体域网动作分类算法计算开销。

假设原始体域网动作训练样本集合记作  $X = [X_1, X_2, \dots, X_k]$ ，其中  $k$  表示动作类别数量。对于测试样本  $y$ ，基于最近邻原则寻找其  $m$  个近邻类的基本思路为：首先计算所有动作类别样本中心点(Sample center,  $SC$ )，随后计算所有  $SC$  与  $y$  的欧氏距离  $dist(y, X_i), (i = 1, 2, \dots, k)$ ，并选取其中与  $y$  距离最小的  $m$  个动作类别作为  $y$  的近邻类。在得到  $y$  的近邻类之后，再根据最近邻原则寻找  $y$  的近邻样本，基本思路为：遍历  $class_y$  所含动作类别，计算每一类别所含动作训练样本与  $y$  的欧氏距离，选取其中距离值最小的  $n$  个训练样本作为  $y$  的近邻样本，然后将所有被选中训练样本拼合构成  $y$  的训练样本集。该算法具体步骤描述如下：

**步骤 1:** 求解训练样本集中每一类别动作集合  $SC$ ，如式(3-1)。

$$SC_i = 1/p_i \sum_{j=1}^{p_i} x_{i,j} \quad (3-1)$$

式中， $p_i$  表示训练样本集合所含第  $i$  类动作样本总数量。

**步骤 2:** 采用欧式距离衡量不同动作模式类别与测试样本的亲疏关系。计算不同动作类别  $SC$  与测试样本之间的欧氏距离，如式(3-2)。

$$\text{dist}(y, SC_i) = \sqrt{\sum_{j=1}^d (SC_{i,j} - y_j)^2} \quad (3-2)$$

式中， $i=1,2,\dots,k$ ， $SC_{i,j}$  和  $y_j$  分别表示第  $i$  类别动作模式样本中心点和待定测试样本  $y$  第  $j$  个元素值， $d$  表示动作样本维度。选取与测试样本距离最小的  $m$  个动作类别作为其近邻类别，记作  $\text{class}_y = [c_1, c_2, \dots, c_m]$ 。

**步骤 3:** 对于  $\text{class}_y$  中第  $i$  ( $i=1,2,\dots,m$ ) 类动作模式，计算该类别每一个动作样本与  $y$  的欧氏距离，选择其中距离最小的  $n$  个动作样本作为该类的训练样本，并记作  $X_i^y = [x_{i,1}, x_{i,2}, \dots, x_{i,n}]$ 。重复该步骤，直到找出  $\text{class}_y$  中每个元素的  $n$  个近邻样本。测试样本  $y$  的近邻样本集记作  $X^y = [X_1^y, X_2^y, \dots, X_m^y]$ ，由所有被选中近邻样本拼合构成。

### 3.2.2 鲁棒协作表示分类模型

SRC 算法强调表示系数的稀疏性的同时，也在一定程度上展示了协作表示机制（例如，测试样本由全部训练样本线性表示），但未能有效发挥协作表示机制优越性。鲁棒协作表示分类 (Robust Collaborative Representation Classification, RCRC) 模型假设动作样本之间存在相似性，基于少量训练样本准确获取测试样本系数表示系数和残差，保证动作识别率的同时降低体域网动作模式识别算法计算开销。假设给定训练样本集合记作  $X = [X_1, X_2, \dots, X_k] = [x_{1,1}, x_{1,2}, \dots, x_{k,p_k}]$ ，其中  $k$  表示动作类别总数量， $p_i$  ( $i=1,2,\dots,k$ ) 表示  $X$  中所含第  $i$  类动作类别样本数量。测试样本  $y$  可由训练样本集  $X$  线性表示，如式(3-3)。

$$y = X\alpha + e \quad (3-3)$$

式中， $\alpha$  表示  $y$  基于  $X$  的表示系数， $e$  表示误差容忍限制。若采用  $l_1$  范式求解测试样本  $y$  的表示残差，则 RCRC 模型定义如式(3-4)。

$$\alpha' = \arg \min \|e\|_1 + \lambda \|\alpha\|_2^2 \quad \text{s. t. } y = X\alpha + e \quad (3-4)$$

式中， $\lambda$  是一个常数。式(3-4)所示是一个限定性凸优化问题，此处采用 ALM 算法进行求解。式(3-4)对应 ALM 方程如式(3-5)。

$$L_\mu(e, \alpha, z) = \|e\|_1 + \lambda \|\alpha\|_2^2 + \langle z, y - X\alpha - e \rangle + \mu/2 \|y - X\alpha - e\|_2^2 \quad (3-5)$$

式中,  $\mu > 0$  是一个常数,  $Z$  表示拉格朗日乘数向量。ALM 算法以迭代的方式估算拉格朗日乘数和优化结果, 具体计算过程如式(4-6)和(4-7)所示。

$$(e_{k+1}, \alpha_{k+1}) = \arg \min L_{\mu_k}(e, \alpha, z_k) \quad (3-6)$$

$$z_{k+1} = z_k + \mu_k (y - X\alpha - e) \quad (3-7)$$

当  $\{\mu_k\}$  满足单调递增正序列<sup>[71]</sup>条件时, 式(3-6)和(3-7)收敛于式(3-4)的优化结果。ALM 算法迭代过程第一步, 即式(3-6)的求解, 可通过迭代方式更新  $e$  和  $\alpha$  得以实现, 如式(3-8)。

$$\begin{cases} \alpha_{k+1} = \arg \min L_{\mu_k}(\alpha, e_k, z_k) \\ e_{k+1} = \arg \min L_{\mu_k}(\alpha_{k+1}, e, z_k) \end{cases} \quad (3-8)$$

式(3-8)所示问题具体求解过程如式(3-9)。

$$\begin{cases} \alpha_{k+1} = (X^T X + 2\lambda/\mu_k I)^{-1} X^T (y - e_k + z_k/\mu_k) \\ e_{k+1} = S_{1/\mu_k} [y - X\alpha_{k+1} + z_k/\mu_k] \end{cases} \quad (3-9)$$

式中, 函数  $S_\alpha, \alpha \geq 0$  是定义分量的收缩算子, 该收缩算子定义如式(3-10)。

$$[S_\alpha(x)]_i = \text{sign}(x_i) \cdot \max\{|x_i| - \alpha, 0\} \quad (3-10)$$

显然, 对于给定常数  $\mu_k$ ,  $P_k = (X^T X + 2\lambda/\mu_k I)^{-1} X^T$  与测试样本  $y$  无关。因此,  $P_k$  可以在处理待定测试样本之前通过计算得到, 作为投影矩阵。在 ALM 算法初始阶段, 可以简单地通过计算  $P_k * y$  得到待定测试样本  $y$  在  $P_k$  之上的投影值, 该操作能够减少算法运行时间。获得待定测试样本  $y$  表示系数  $\alpha'$  和表示残差  $e'$  后, 求解  $y$  与不同动作模式类别正则化残差, 如式(3-11)。

$$\text{err}_i(y) = \|y - X_i \alpha_i' - e'\|_2 / \|\alpha_i'\|_2 \quad (3-11)$$

式中,  $i = 1, 2, \dots, k$ ,  $\text{err}_i(y)$  表示测试样本  $y$  与第  $i$  类动作模式类别的正则化残差。最后根据逼近残差原则, 选取  $\text{err}_i(y)$  所含全部元素中最小值所对应动作类别作为  $y$  所属类别。

---

#### 算法：鲁棒协作表示分类算法

---

1. 初始化:  $\lambda, \mu_k, X$  逐列归一化;
  2. 迭代更新:
    - (1) 计算:  $\alpha_{k+1} = (X^T X + 2\lambda/\mu_k I)^{-1} X^T (y - e_k + z_k/\mu_k)$ ;
    - (2) 计算:  $e_{k+1} = S_{1/\mu_k} [y - X\alpha_{k+1} + z_k/\mu_k]$ ;
-



- 
- (3) 计算:  $z_{k+1} = z_k + \mu_k (y - X\alpha - e)$ ;
  - (4) 收敛后输出: 协作表示系数  $\alpha'$  和表示残差  $e'$ ;
  - 3. 计算正则化残差:  $err_i(y) = \|y - X_i\alpha_i' - e'\|_2 / \|\alpha_i'\|_2$ ;
  - 4. 输出判别结果:  $identity(y) = \arg \min_i \|err_i\|$ 。
- 

### 第三节 实验结果与分析

#### 3.3.1 数据库与数据预处理

本研究采用公开发布的可穿戴动作识别数据库 WARD 验证本章所提算法有效性。该数据库将五个传感器采集节点（内嵌有一个 3 轴加速度传感器和一个 2 轴陀螺仪）分别佩戴于测试者的左右手腕、左右脚踝和腰部等部位，共计记录了 20 名测试者 13 种动作模式（包含站、坐、躺、向前走、逆时针走、顺时针走、向左转、向右转、上楼、下楼、慢跑、跳和推轮椅）数据。本实验选取其中较为常用的 9 种动作模式（包括站、坐、向前走、向左转、向右转、上楼、下楼、慢跑和跳）数据作为试验数据。

为确保所选动作样本包含完整动作信息，本实验采用滑动窗口方法截取数据段，窗口长度设为 200 点。选用 3 个方向的加速度数据和 2 个方向的陀螺仪数据定义人体动作样本，则动作样本的维度为  $d = 1000$ 。所选动作样本采用五阶平滑滤波进行数据消噪。为客观准确地评价本章所提算法的性能，我们选取 18 名测试者的动作数据作为训练样本，剩余 2 名受试者的动作数据作为测试样本。重复该过程 100 次，取最终的平均结果作为本章所提算法的实验结果。

#### 3.3.2 实验结果和分析

由于提取动作样本维度高达  $d = 1000$ ，其中存在大量冗余信息，影响动作分类算法性能。为降低动作样本冗余性，实验中采用随机投影方法（本实验中投影矩阵取稀疏二进制矩阵）压缩动作样本，压缩率 (Compressive Rate, CR) 定义为：

$$CR = d'/d \quad (3-14)$$

式中， $d$  表示动作样本原始维度， $d'$  表示压缩后动作样本维度。 $CR$  取值越小则表示数据压缩程度越高，反之亦然。

首先，为使得本章所提算法识别性能达到最优，取  $CR = 0.5$ ，考察 FRCRC 算法

基于不同数量近邻类和近邻样本所取得人体动作识别率，实验结果如表 3-1 所示。从表中可以看出，FRCRC 算法动作识别率并没有随着近邻类数量和近邻样本数量增加而呈现出上升的趋势。其中最高识别率出现在当近邻类数量取 4 且近邻样本数量取 10 的条件下，达到 94.94%。当近邻类别数量取 2 及每类近邻样本数量取 5，即动作训练样本数量最小（仅限表 2 中）时，识别率仅为 89.39%，其原因在于动作训练样本数量过少，无法为协作表示分类模型提供足够判别信息。当近邻类别数量取 8 及每类近邻样本数量取 30，即动作训练样本数量最大（仅限表 3-1 中）时，识别率仅为 90.11%，其原因在于选取动作训练样本数量过多，其中含有大量冗余信息，削弱动作识别算法性能。

表 3-1 本章所提算法基于不同数量近邻类（行）和近邻样本（列）识别率

Tab. 3-1 The accuracy of the proposed algorithm based on different neighbor category numbers (row) and neighbor samples (column)

识别率(%)	2	4	6	8
5	89.39	92.00	92.17	92.56
10	90.11	94.94	94.56	93.06
15	90.78	94.56	93.06	92.89
20	90.39	94.39	92.67	90.50
25	90.50	93.78	92.89	90.22
30	90.39	93.83	91.61	90.11

实验中，我们选取 SRC\_RP 和 FSRC\_RP 算法与本章所提 FRCRC 算法比较，进一步客观评价本章所提 FRCRC 算法有效性。FRCRC 算法中近邻类数量取 4，每个近邻类中近邻样本数量取 10，三种算法动作识别率比较结果如图 3-2 所示，识别相同数量（90 个）动作样本所耗时间比较结果如图 3-3 所示。从图 3-2 可以看出，三种动作识别算法所取得动作识别率均随着动作样本维度增加（ $CR$  取值越大，动作样本维度越高）而增长。FRCRC 算法可获得动作识别率最高为 95.78%（ $CR=0.9$  时），而 FSRC\_RP 和 SRC\_RP 算法所获得动作识别率最高分别达到 94%（ $CR=1.0$  时）、93%（ $CR=1.0$  时）。相较而言，本章所提 FRCRC 算法对于体域网动作分类性能明显优于另外两种分类算法。其原因在于，本章所提算法基于近邻原则为测试样本寻找具有高相似度的近邻样本构建训练样本集，并通过构建协作表示分类模型，充分利用动作样本之间存在的相似性，获取测试样本精确的表示系数和表示残差，准确识

别多类别动作样本。




图 3-2 基于不同算法取得动作识别率比较

Fig. 3-2 The comparison of activity recognition rate based on different algorithms

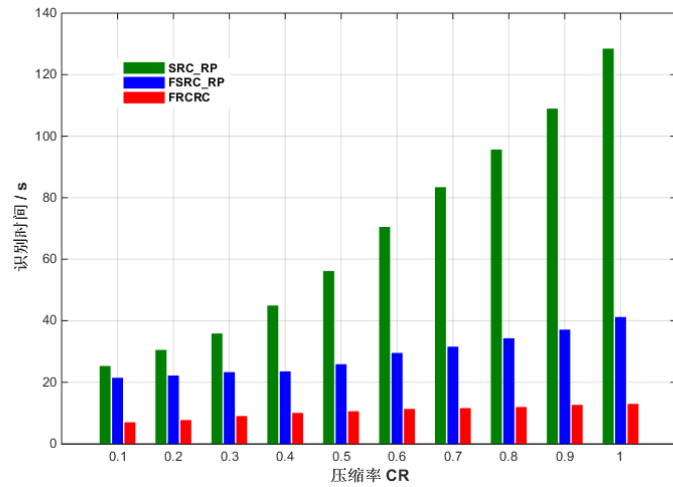


图 3-3 基于不同种类算法的识别时间比较

Fig. 3-3 The comparison of recognition time based on different algorithms

从图 3-3 可以看出，三种动作识别算法识别相同数量动作样本所消耗时间均随着动作样本维度增加而增长。其中，SRC\_RP 算法所消耗时间明显多于另外两种算法，而且受动作样本维度增加影响明显（呈曲线增长趋势）。FRCRC 算法所消耗时间最少，而且受动作样本维度增加影响较小。其原因在于本章所提算法基于近邻原

则为测试样本构建规模较小的训练样本，减少算法处理的数据量，降低分类算法复杂度。这些结果表明，本章所提算法能够充分发掘动作样本之间存在的相似性，有效降低传感器采集节点的功耗，同时显著提升体域网动作模式分类性能。

表 3-2 FSRC\_RP 算法基于 9 种动作模式的混淆矩阵

Tab. 3-2 The confusion matrix of FSRC\_RP algorithm based on 9 categories of activity pattern

	站	坐	向前走	向左转	向右转	上楼	下楼	慢跑	跳	识别率
站	900	0	0	86	14	0	0	0	0	0.900
坐	1	990	0	0	0	0	0	9	0	0.990
向前走	67	0	859	72	2	0	0	0	0	0.859
向左转	97	0	0	903	0	0	0	0	0	0.903
向右转	0	0	0	0	1000	0	0	0	0	1.00
上楼	1	0	34	0	0	920	45	0	0	0.920
下楼	0	1	2	0	0	48	851	98	0	0.851
慢跑	100	0	0	0	0	0	1	899	0	0.899
跳	121	0	0	0	0	1	1	2	875	0.875
召回率	0.614	0.999	0.955	0.851	0.984	0.949	0.948	0.892	1.00	

表 3-3 FRCRC 算法基于 9 种动作模式的混淆矩阵

Tab. 3-3 The confusion matrix of FRCRC algorithm based on 9 categories of activity pattern

	站	坐	向前走	向左转	向右转	上楼	下楼	慢跑	跳	识别率
站	897	3	0	77	23	0	0	0	0	0.897
坐	0	1000	0	0	0	0	0	0	0	1.00
向前走	113	0	887	0	0	0	0	0	0	0.887
向左转	0	0	7	987	6	0	0	0	0	0.987
向右转	1	0	0	0	999	0	0	0	0	0.999
上楼	0	16	1	0	2	935	46	0	0	0.935
下楼	11	4	3	0	0	0	982	0	0	0.982
慢跑	0	0	27	0	0	17	68	888	0	0.888
跳	5	1	0	0	0	6	0	0	988	0.988
召回率	0.873	0.976	0.959	0.927	0.970	0.976	0.896	1.00	1.00	

此外，在实验中，我们基于最优近邻类数量，近邻样本数量以及  $CR=1$  条件下，比较本章所提 FRCRC 算法和 FSRC\_RP 算法对于所选 9 种不同动作模式识别性能。FSRC\_RP 算法和 FRCRC 算法所取得的混淆矩阵分别如表 3-2 和表 3-3 所示。从表 3-2 可以看出，FSRC\_RP 算法仅对于坐和向右转 2 种动作模式的识别率达到 95% 以上，对于站、向前走、下楼、慢跑和跳等 5 种动作模式类别的识别率均未超过 90%，9 种动作模式平均识别率也仅有 91%。从表 3-3 可以看出，本章所提 FRCRC 算法对于坐、向左转、向右转、下楼和跳等 5 种动作模式识别率均达到 98% 以上，9 种动作模式平均识别率达到 95% 以上，比之 FSRC\_RP 算法高出近 4%。综上所述，本章

所提算法能够寻找与测试样本具有较高相似度的近邻类和近邻样本，基于较少训练样本精确地协作表示多种动作模式样本。较之稀疏表示体域网动作分类算法，FRCRC 算法能够有效降低动作分类算法复杂度，同时显著提升体域网动作模式识别率，对于基于体域网实时监测人体动作变化具有重要现实意义。

#### 第四节 本章小结

本章提出一种快速鲁棒性协作表示动作识别算法。该算法基于最近邻原则在所有训练样本中选取一部分作为测试样本的新训练样本集，并基于该样本集构建快速鲁棒协作表示动作识别模型，更加快速、精确地获取测试样本对应的稀疏表示系数和表示残差，显著提升体域网动作模式识别率，同时大幅降低算法时间复杂度。本章以 FSRC\_RP 和 SRC\_RP 两种算法作为比较，在相同条件下，本章所提算法平均识别率较两种算法有显著提升，算法运行时间更少，为基于体域网实时监测人体动作变化提供一种新思路和方法。



## 第四章 结论

### 第一节 论文工作总结

体域网动作模式识别算法研究在医疗康复监测、影视和游戏制作以及专业动作分析等领域已经取得十分广泛的关注和应用。相关研究人员尝试采用惯性传感器、加速度传感器等常用采集节点构建无线体域网,并将这些节点佩戴于人体关节部位,用于记录人体动作数据,为动作模式识别算法提供精确数据来源。在识别算法的选择上,近年来相关研究先后经历了机器学习算法和稀疏表示分类算法为代表的两个阶段,均取得较好进展。当前,如何提升体域网人体动作模式识别性能,有效降低体域网动作识别算法时间复杂度成为该研究方向的热点研究课题。本文针对上述问题,从字典优化学习、准确估算体域网动作样本稀疏表示系数等多个角度展开工作,现将主要工作内容及成果总结如下:

(1) 提出了一种基于 K-SVD 的最大似然稀疏表示动作分类算法。该算法可有效利用 K-SVD 优化学习算法,将不同动作模式训练样本按其所属类别分组优化训练,避免各类样本数据训练时相互干扰,将不同动作模式类别所属的子字典拼合一个完整字典,准确稀疏表示测试样本,使最大似然稀疏模型准确估计稀疏表示系数残差。实验证明了最大似然稀疏表示模型能够基于经过 K-SVD 算法训练所得完备字典准确估算人体动作测试样本的稀疏表示系数,有效提高动作模式分类性能,有助于判别动作模式连续变化。

(2) 提出了一种基于 D-KSVD 算法的联合稀疏表示人体动作识别算法。该算法基于改进 D-KSVD 算法优化字典,有机融合体域网多传感器动作信号,通过联合稀疏表示算法发掘更多的人体动作信号之间的时空相关性信息,采用联合重构准确获取测试样本的稀疏表示系数,并依此判别测试样本所属类别。实验证明了所提算法能够有效利用不同人体动作信号之间的时空相关性,提升体域网人体动作模式识别性能。

(3) 提出了一种快速鲁棒性协作表示动作识别算法。该算法基于最近邻原则在所有训练样本中选取一部分作为测试样本的新训练样本集,并构建快速鲁棒协作表示动作识别模型,更加快速、精确地获取测试样本对应的稀疏表示系数和表示残差,显著提升体域网动作模式识别率,同时大幅降低算法时间复杂度。实验证明,选择

FSRC\_RP 和 SRC\_RP 两种算法作为参照,在相同条件下,本文算法平均识别率比之两种算法有显著提升,平均识别时间更少,有效降低了体域网动作模式识别算法算法复杂度。

## 第二节 未来工作展望

本文围绕体域网人体动作模式识别问题,从字典优化学习、稀疏表示系数准确重构等方面初步探讨如何提高人体动作识别率和降低时间复杂度等问题,取得了一定的研究成果,但论文仍然存在不足之处,需要进一步完善与改进。

(1) 关于字典学习算法,本文中所提出的三种人体识别算法中采用了三种不同的字典优化设计方法。根据实验结果可以看出,采用字典优化设计算法能够一定程度上消除训练样本集合信息冗余度,提升人体动作模式识别率,但仅是字典学习算法与识别算法(如 SRC,JSRC,CRC 等)的简单结合,并没有完全发挥出字典优化设计算法的优势。为多传感器体域网人体动作信号设计更加匹配的字典学习算法,以期获得规模更小、判别性能更强的字典。

(2) 在稀疏表示系数计算,即信号重构方面,本文尝试采用最大似然稀疏表示模型、JSRC 算法以及 CRC 算法获取测试动作样本稀疏表示系数,再依据该表示系数得到测试样本对应表示残差,判定测试样本所属动作类别。然而,上述几种算法均在某些方面存在不足,或是算法开销较大,或是无法高效利用不同传感器节点人体动作数据之间存在的时空相关性精确表示动作测试样本等等。因此,基于多传感器体域网所记录人体动作数据,进一步探索更加高效、低能耗的识别算法是后续研究努力方向。

总而言之,多传感器体域网人体动作模式识别依然是一个新兴研究领域,在理论研究、实际运用中均具有特殊研究意义,在今后研究工作中需要更多相关科研工作者开展广泛而深入的研究。



## 参考文献

- [1] Foerster F, Smeja M, Fahrenberg J. Detection of posture and motion by accelerometry: a validation study in ambulatory monitoring[J]. Computers in Human Behavior, 1999, 15(5):571-583.
- [2] Cai J X, Tang X, Feng G. Learning pose dictionary for human action recognition[C]. International Conference on Pattern Recognition. IEEE, 2014:381-386.
- [3] Hu J F, Zheng W S, Lai J, et al. Jointly learning heterogeneous features for RGB-D activity recognition[C]. Computer Vision and Pattern Recognition. IEEE, 2015:5344-5352.
- [4] 陈鹏光. 基于稀疏模型的运动跟踪识别算法[D]. 华南理工大学, 2016.
- [5] Lara O D, Labrador M A. A survey on human activity recognition using wearable sensors[J]. IEEE Communications Surveys & Tutorials, 2013, 15(3):1192-1209.
- [6] Movassaghi S, Albolhasan M, Lipman J, Smith D, Jamalipour A. Wireless body area networks: A Survey[J]. IEEE Communication and Tutorials, 2014, 16(3): 1658-1686.
- [7] Rawat P, Singh KD, Chaouchi H, Bonnin JM. Wireless sensor networks: A survey on recent developments and potential synergies[J]. Journal of Supercomputing, 2014, 68: 1-48.
- [8] Nigussie E, Xu T, Potkonjak M. Securing wireless body sensor networks using bijective function-based hardware primitive [C]. 2015 International Conference on Intelligent Sensors, Sensor Networks and Information Processing Singapore, pp. 1-6 , Apr, 2015.
- [9] Poon CCY, Lo BPL, Yuce MR. Body sensor networks: in the era of big data and beyond [J]. IEEE Reviews in Biomedical Engineering, 2015, 8: 4-16.
- [10] Huang H, Li X, Sun Y, et al. A triboelectric motion sensor in wearable body sensor network for human activity recognition[C]. Conf Proc IEEE Eng Med Biol Soc, 2016:4889.
- [11] Cohn G, Gupta S, Lee T J, et al. An ultra-low-power human body motion sensor using static electric field sensing[C]. ACM Conference on Ubiquitous Computing. ACM,

2012:99-102.

- [12] Kim S, Brendle C, Lee H Y, et al. Evaluation of a 433 MHz Band Body Sensor Network for Biomedical Applications[J]. *Sensors*, 2013, 13(1):898-917.
- [13] Pérez J J, Saldarriaga A J, Bustamante J. A wireless body sensor network platform to measure vital signs in clinical monitoring[C]. *Health Care Exchanges. IEEE*, 2013:1-6.
- [14] 武东辉. 基于惯性传感器数据的人体日常动作识别研究[D]. 大连理工大学, 2016.
- [15] 杨海涛. 基于惯性传感器的人体动作识别研究[D]. 哈尔滨工业大学, 2016.
- [16] Wright J, Yang A Y, Ganesh A, et al. Robust Face Recognition via Sparse Representation[J]. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, 2009, 31(2):1-18.
- [17] Yang A Y, Jafari R, Sastry S S, et al. Distributed recognition of human actions using wearable motion sensor networks[J]. *Journal of Ambient Intelligence & Smart Environments*, 2009, 1(2):103-115.
- [18] Zhang M, Sawchuk A A. Human daily activity recognition with sparse representation using wearable sensors[J]. *IEEE Journal of Biomedical & Health Informatics*, 2013, 17(3):553-560.
- [19] Zhu C, Sheng W. Human daily activity recognition in robot-assisted living using multi-sensor fusion[C]. *IEEE International Conference on Robotics and Automation. IEEE Press*, 2009:3644-3649.
- [20] Ling B, Intille S S. Activity Recognition from user-annotated acceleration data[C]. *Pervasive Computing, Second International Conference, PERVASIVE 2004, Vienna, Austria, April 21-23, 2004, Proceedings. DBLP*, 2004:1-17.
- [21] Riboni D, Bettini C. COSAR: Hybrid reasoning for context-Aware activity recognition[J]. *Personal & Ubiquitous Computing*, 2011, 15(3):271-289.
- [22] Anguita D, Ghio A, Oneto L, et al. Energy efficient smartphone-based activity recognition using fixed-point arithmetic[J]. *Journal of Universal Computerence*, 2013, 19(9):1295-1314.
- [23] Martín H, Bernardos A M, Iglesias J, et al. Activity logging using lightweight classification techniques in mobile devices[J]. *Personal & Ubiquitous Computing*,

- 2013, 17(4):675-695.
- [24] Siirtola P, Rönning J. Ready-to-use activity recognition for smartphones[C]. Computational Intelligence and Data Mining. IEEE, 2013:59-64.
- [25] Zhang M, Sawchuk AA. USC-HAD: a daily activity dataset for ubiquitous activity recognition using wearable sensors[C]. ACM Conference on Ubiquitous Computing. 2012:1036-1043.
- [26] Huỳnh T, Schiele B. Unsupervised discovery of structure in activity data using multiple eigenspaces[C]. Location- and Context-Awareness, Second International Workshop, LoCA 2006, Dublin, Ireland, May 10-11, 2006, Proceedings. DBLP, 2006:151-167.
- [27] Krause A, Siewiorek D P, Smailagic A, et al. Unsupervised, dynamic identification of physiological and activity context in wearable computing[C]. IEEE International Symposium on Wearable Computers. IEEE Computer Society, 2003:88.
- [28] Massé F, Gonzenbach R R, Arami A, et al. Improving activity recognition using a wearable barometric pressure sensor in mobility-impaired stroke patients[J]. Journal of NeuroEngineering and Rehabilitation, 2015, 12(1):72.
- [29] Attal F, Mohammed S, Dedabrishvili M, et al. Physical Human Activity Recognition Using Wearable Sensors[J]. Sensors, 2015, 15(12):31314-31338.
- [30] Ong W H. An unsupervised approach for human activity detection and recognition[J]. International Journal of Simulation Systems Science & Technology, 2013, 14(5).
- [31] Cottone P, Re G L, Maida G, et al. Motion sensors for activity recognition in an ambient-intelligence scenario[C]. IEEE International Conference on Pervasive Computing and Communications Workshops. IEEE, 2013:646-651.
- [32] Zhang T, Wang J, Xu L, et al. Using wearable sensor and NMF algorithm to realize ambulatory fall detection[C]. International Conference on Advances in Natural Computation. Springer-Verlag, 2006:488-491.
- [33] Chamroukhi F, Mohammed S, Trabelsi D, et al. Joint segmentation of multivariate time series with hidden process regression for human activity recognition[J]. Neurocomputing, 2013, 120(7):633-644.
- [34] Jatobá L C, Grossmann U, Kunze C, et al. Context-aware mobile health monitoring: evaluation of different pattern recognition methods for classification of physical

- activity[C]. International Conference of the IEEE Engineering in Medicine & Biology Society. Conf Proc IEEE Eng Med Biol Soc, 2008:5250.
- [35]Ermes M, Parkka J, Cluitmans L. Advancing from offline to online activity recognition with wearable sensors[J]. Conf Proc IEEE Eng Med Biol Soc, 2008, 2008(1):4451-4454.
- [36]Vinh LT, Lee S, Le HX, et al. Semi-Markov conditional random fields for accelerometer-based activity recognition[J]. Applied Intelligence, 2011, 35(2):226-241.
- [37]Trabelsi D, Mohammed S, Chamroukhi F, et al. An unsupervised approach for automatic activity recognition based on hidden Markov model regression[J]. IEEE Transactions on Automation Science & Engineering, 2013, 10(3):829-835.
- [38]Lester J, Choudhury T, Kern N, et al. A hybrid discriminative/generative approach for modeling human activities[C]. International Joint Conference on Artificial Intelligence. Morgan Kaufmann Publishers Inc. 2005:766-772.
- [39]He Z, Jin L. Activity recognition from acceleration data based on discrete cosine Transform and SVM[J]. IEEE, 2009:5041-5044.
- [40]Zhen-Yu HE, Jin L W. Activity recognition from acceleration data using AR model representation and SVM[C]. International Conference on Machine Learning and Cybernetics. IEEE, 2008:2245-2250.
- [41]He Z, Liu Z, Jin L, et al. Weightlessness feature — a novel feature for single tri-axial accelerometer based activity recognition[C]. International Conference on Pattern Recognition. IEEE, 2008:1-4.
- [42]Huynh T, Schiele B. Towards Less Supervision in Activity Recognition from Wearable Sensors[C]. IEEE International Symposium on Wearable Computers. IEEE, 2006:3-10.
- [43]Krause A, Ihmig M, Rankin E, et al. Trading off prediction accuracy and power consumption for context-aware wearable computing[C]. IEEE International Symposium on Wearable Computers. IEEE Computer Society, 2005:20-26.
- [44]Doukas C, Maglogiannis I. Advanced patient or elder fall detection based on movement and sound data[C]. International Conference on Pervasive Computing Technologies for Healthcare, 2008. Pervasivehealth. IEEE, 2008:103-107.
- [45]Randell C, Muller H. Context awareness by analysing accelerometer data[C].

- International Symposium on Wearable Computers. IEEE, 2000:175-176.
- [46] Jian BY, Minh NN, Phyo PS, et al. Deep conventional neural networks on multichannel time series for human activity recognition[C]. Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI 2015). AAAI, 2015: 3995-4001.
- [47] Bedogni L, Felice M D, Bononi L. By train or by car? Detecting the user's motion type through smartphone sensors data[C]. Wireless Days. IEEE, 2013:1-6.
- [48] Andrea M, Maria S A. Machine learning methods for classifying human physical activity from on-body accelerometers[J]. Sensors, 2010, 10(2):1154.
- [49] Altun K, Barshan B, Tunçel O. Comparative study on classifying human activities with miniature inertial and magnetic sensors[J]. Pattern Recognition, 2010, 43(10):3605-3620.
- [50] 肖玲, 李仁发, 罗娟. 体域网中一种基于压缩感知的人体动作识别方法[J]. 电子与信息学报, 2013, 35(1):119-125.
- [51] Yuan X T, Liu X, Yan S. Visual Classification With Multitask Joint Sparse Representation[M]. IEEE Press, 2012:4349-4360.
- [52] Xiao L, Li R, Luo J, et al. Activity Recognition via Distributed Random Projection and Joint Sparse Representation in Body Sensor Networks[J]. Communications in Computer & Information Science, 2013, 418:51-60.
- [53] Zhang L, Yang M, Feng X. Sparse representation or collaborative representation: Which helps face recognition?[C]. IEEE International Conference on Computer Vision. IEEE, 2012:471-478.
- [54] Zhang L, Yang M, Feng XC, Ma Y, Zhang D. Collaborative representation based classification for face recognition[C]. 2011 IEEE International Conference on Computer Vision(ICCV), Barcelona, Spain, 2011.
- [55] Yang M, Zhang L, Yang J, et al. Robust sparse coding for face recognition[C]. Computer Vision and Pattern Recognition. IEEE, 2011:625-632.
- [56] 胡正平, 宋淑芬. 基于类别相关近邻子空间的极大似然稀疏表示鲁棒图像识别算法[J]. 自动化学报, 2012, 38(9):1420-1427.
- [57] Aharon M, Elad M, Bruckstein A. K-SVD: An Algorithm for Designing Overcomplete

- Dictionaries for Sparse Representation[J]. IEEE Transactions on Signal Processing, 2006, 54(11):4311-4322.
- [58]Zhang Q, Li B. Discriminative K-SVD for dictionary learning in face recognition[C]. Computer Vision and Pattern Recognition. IEEE, 2010:2691-2698.
- [59]Serra J G, Testa M, Molina R, et al. Bayesian K-SVD Using Fast Variational Inference[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2017, PP(99):1-1.
- [60]Jiang Z, Lin Z, Davis L S. Label Consistent K-SVD: Learning A Discriminative Dictionary for Recognition[J]. IEEE Trans Pattern Anal Mach Intell, 2013, 35(11):2651-2664.
- [61]陈才扣, 喻以明, 史俊. 一种快速的基于稀疏表示分类器[J]. 南京大学学报(自然科学), 2012, 48(1):70-76.
- [62]吴建宁, 徐海东, 王佳境,等. 基于随机投影的快速稀疏表示人体动作识别方法 [J]. 中国生物医学工程学报, 2016, 35(1):38-46. [J]. 中国生物医学工程学报, 2016, 35(1): 38-46.
- [63]Zhang J, Jin R, Yang YM, Hauptmann AG. Modified logistic regression: an approximation to SVM and its applications in large-scale text categorization. Proceedings of the Twentieth International Conference on Machine Learning. Washington D.C.: AAAI, 2003: 888–895.
- [64]Yin HP, Yang SX. A survey on distributed compressed sensing: theory and applications [J]. Frontiers of Computer Science, 2014, 8: 893-904.
- [65]Duarte MF, Sarvotham S., Baron D. Distributed compressed sensing of jointly sparse signals[C]. Proceedings of Asilomar Conference on Signal System on Computing, California, United States, 2005.
- [66]Wang Q, Liu ZW. A robust and efficient algorithm for distributed compressed sensing [J]. Computer and Electrical Engineering, 2011, 37: 916-926.
- [67]Ji S, Dunson D, Carin L. Multitask compressive sensing [J]. IEEE Transactions On Signal Processing, 2009, 57(1): 92-106.
- [68]Zhu PF, Zuo WM, Zhang L, Shiu SCK, Zhang D. Image set based collaborative representation for face recognition[C]. IEEE Transactions on Information Forensics

- and Security, vol. 9, no. 7, pp. 1120-1132, July, 2014.
- [69] Cai SJ, Zhang L, Zuo WM, Feng XC. A probabilistic collaborative representation based approach for pattern classification[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition.
- [70] Li W, Du Q. Joint within-class collaborative representation for hyperspectral image classification[J]. IEEE Journal of selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(6): 2200-2208.
- [71] Bertsekas D. Nonlinear Programming, Athena Scientific, 2003.
- [72] Lin Z., Chen M., Wu L., Ma Y. The augmented lagrange multiplier method for exact recovery of corrupted low-rank matrices. UIUC Technical Report UILU-ENG-09-2215, 2009.
- [73] Jijesh JJ, Shivashankar. A survey on Wireless Body Sensor Network routing protocol classification[C]. International Conference on Intelligent Systems and Control. IEEE, 2017:489-494.
- [74] Lee S W, Mase K. Activity and location recognition using wearable sensors[J]. Pervasive Computing IEEE, 2002, 1(3):24-32.
- [75] 徐海东.面向低功耗体域网的人体运动模式远程识别技术研究[D].福建师范大学,2016.
- [76] 王佳境,吴建宁,凌云,李杰成.基于 K-SVD 的最大似然稀疏表示体域网动作分类算法.计算机系统应用,2018,27(2):144-150.
- [77] Wu JN, Wang JJ, Ling Y, Xu HD. An advanced hybrid technique of DCS and JSRC for Telemonitoring of Multi-Sensor Gait Pattern. Sensors, 2017, 17(12):2764-2782.





## 攻读学位期间承担的科研任务与主要成果

### 已发表和录用学术论文：

1. **XXX,XXX,XXX,XXX**.基于 K-SVD 的最大似然稀疏表示体域网动作分类算法.计算机系统应用,2018,27(2):144-150.
2. **XXX,XXX,XXX,XXX**.An advanced hybrid technique of DCS and JSRC for Telemonitoring of Multi-Sensor Gait Pattern. Sensors, 2017, 17(12):2764-2782. ( DOI:10.3390/s17122764, SCI-III)
3. **XXX,XXX,XXX,XXX**.基于随机投影的快速稀疏表示人体动作识别方法[J].中国生物医学工程学报,2016,35(1):36-46.
4. **XXX,XXX,XXX,XXX**.基于块稀疏贝叶斯学习的人体运动模式识别[J].计算机应用,2016,36(4):1039-1044.

### 参与科研项目：

1. 福建省省属高校科研专项项目，JK2016006，用于早期评价老年人跌倒风险的可穿戴远程预警系统，2016/07-2019/06.
2. 福建省科技厅引导性项目（省重点项目），2017Y0028，预测社区老年人跌倒风险的体域网步态远程监测系统关键技术研究，2017/06-2020/04.

### 已登记软件著作权：

1. **XXX,XXX,XXX,XXX**.一种体域网中基于多因子优先级的时隙分配方法(发明专利)，申请号或专利号：201710261711.8。
2. **XXX,XXX,XXX,XXX**.基于无线体域网的可穿戴式行走监测系统及其监测方法(发明专利) 申请号或专利号：201710208137.X。
3. **XXX,XXX,XXX,XXX**.基于 web 的老人健康分析系统。软件著作权登记号：2016SR377675。
4. **XXX,XXX,XXX,XXX**.关爱老年人健康新闻系统。软件著作权登记号：2017SR041233。

5. **XXX,XXX,XXX,XXX**. 健康数据远程处理系统。软件著作权登记号：  
2018R11L068343。
6. **XXX,XXX,XXX,XXX**. 老人健康商城系统。软件著作权登记号：流水号：  
2018R11L062955。

## 致 谢

行文至此，意味着三年硕士求学经历已进入尾声。在过去两年多的时光中虽然有着太多枯燥和无趣，但也充满了自我成长与提升的感觉、充实和感悟。在研究生阶段即将结束之际，借此文谨向所有给予我帮助、关心和指导的所有老师、同学、朋友以及家人送上本人诚挚的谢意和祝福！

首先要感谢我的硕士导师 XXX 教授一直以来对本人学习、生活关心和帮助。XXX 学识渊博、为人风趣、待人温和，在日常交流过程中给予我耐心的指导，不仅仅指引我做论文，传授我做学问的技巧，还有做学术的态度以及为人处世准则。在该课题进行过程中，XXX 给予指导，及时指正本人所犯错误，并仔细检查各阶段成果，提出修改意见，确保课题以及论文的顺利进行和完成。至该论文截稿之际，再次向 XXX 致以真诚的谢意。

此外，我还要感谢 2015 级诸位计算机系的同学们，大家一起上课、一起学习、共同奋斗，度过了愉快的三年时光。感谢 XXX 师兄在入学初期给予的帮助，让我能够快速展开自己的学术工作。同时还要感谢在成功楼一起学习工作的各位同学和老师对本人学术工作的支持和帮助。

另外，我想借此机会对我的家人表达自己的感激之情，谢谢你们一直以来对我学业的支持和鼓励，让我能够顺利完成学业。

最后，由衷感谢参加本文评审及答辩的各位专家、老师，感谢各位能够提出宝贵意见！

XXXXXX

2018 年 03 月

于福州·仓山 福建师范大学数学与信息学院

